

1. 자료의 형태

1) 질적 자료(범주형 자료)

① 명목형 자료

- 이름이나 문자를 나타내는 자료
- 대소비교 불가, 사칙연산 불가
- 성별, 종교, 사는 지역 등

② 순서형 자료(서열형 자료)

- 이름이나 문자를 나타내는 자료
- 범주들간 순서가 있음
- 대소비교는 가능, 사칙연산 불가
- ex. 설문지에서 매우 그렇지 않다/그렇지 않다/보통이다/그렇다/매우 그렇다

2) 양적 자료(숫자형, 연속형 자료) - 통계분석 시 구간자료와 비율자료의 구분이 필요하지 않음

① 구간 자료(interval)

- 대소비교 가능, 배율 표현 불가
- ex. 온도, IQ, 수능점수, TOEFL 점수 등
- 온도: 섭씨온도는 어는 점 0도, 끓는 점 100도로 정하고 구간을 일정하게 나눔.
40도가 20도보다 두 배 뜨겁다고 말할 수 없음

② 비율자료

- 대소비교 가능, 배율 표현 가능, 사칙연산 가능
- ex. 키, 몸무게, 컴퓨터 수 등
- 40킬로그램이 20킬로그램의 2배다 라고 말할 수 있음

2. 분석 기준

1) 독립표본 T검정, 맨-휘트니 U검정

범주형 변수 1개에 2개 집단이 있는데 그 변수 안에 있는 집단 간의 차이가 있는지 궁금한 변수가 양적 자료다.

독립표본 T-검정 (Independent Samples T-test) / 맨-휘트니 U 검정 (Mann-Whitney U Test)

하나의 범주형 독립변수가 두 개의 독립적인 집단(예: 실험군/대조군, 남성/여성)으로 구성될 때, 이 두 집단 간에 하나의 연속형 종속변수(예: 점수, 혈압)의 평균(또는 중앙값)에 통계적으로 유의미한 차이가 있는지를 검정한다.

2) 대응표본 T검정, 윌콥슨 부호순위 검정

한 대상(사람, 동물, 자동차 등)에 대해 숫자형 자료의 측정을 시간간격을 두고 2번(A약을 먹었을 때와 B약을 먹었을 때) 했는데 그 측정값들 간의 차이가 궁금하다.

대응표본 T-검정 (Paired Samples T-test) / 윌콥슨 부호 순위 검정 (Wilcoxon Signed-Rank Test)

동일한 대상에 대해 두 가지 다른 조건 하에서 또는 두 개의 다른 시점에서 측정한 하나의 연속형 변수 값들 간에 통계적으로 유의미한 차이가 있는지 검정한다. 이는 사전-사후 설계(pre-post design)나 교차 설계(crossover design)에서 평균의 변화를 분석할 때 주로 사용된다.

3) 일원배치 분산분석(ANOVA), 크루스칼-왈리스 검정

범주형 변수 1개에 3개 집단 이상이 있는데 그 변수 안에 있는 집단 간의 차이가 있는지 궁금한 변수가 양적 자료다.

일원배치 분산분석 (One-Way ANOVA) / 크루스칼-왈리스 검정 (Kruskal-Wallis Test)

하나의 범주형 독립변수가 세 개 이상의 독립적인 집단(예: A, B, C 교육 방식)으로 구성될 때, 이 집단들 간에 하나의 연속형 종속변수(예: 학업 성취도)의 평균(또는 중앙값)에 통계적으로 유의미한 차이가 있는지를 검정한다.

3. 통계량, 통계치, 추정량, 추정치, 검정통계량..?

1) 통계량

- 통계분석을 위해 사용하는 공식

2) 통계치

- 통계량이라는 공식에 들어가서 나온 값

3) 추정량

- 추정을 위해 사용하는 통계량

4) 추정치

- 추정량을 통해 나온 값

5) 검정통계량

- 검정을 위해 사용하는 통계량

4. 자유도: 자유롭게 변할 수 있는 값들의 수

표본 5개: 1 2 3 4 ? 표본평균이 3이면 $\rightarrow ? = 3 \rightarrow$ 자유도는 4!

표본 10개: 5 5 5 5 5 5 5 5 5 ? 표본평균이 5이면 $? = 5 \rightarrow$ 자유도는 9!

중심극한정리에 의해 모집단 $X \sim ?(\mu, \sigma^2)$ 에서 충분히 큰 표본을 뽑으면 $\bar{X} \sim N(\mu, \frac{\sigma^2}{n})$

표본평균의 평균과 모집단의 평균이 같으므로 표본평균의 분포를 통해 모평균을 추정할 수 있지만 분산은 도저히 모름... 그렇기 때문에 모표준편차 σ 대신 표본평균의 표준편차(표준오차) S를 사용하여 자유도가 $n-1$ 인 t분포를 따르는 스튜던트화된 확률분포를 얻음

$$\frac{\bar{X} - \mu}{S / \sqrt{n}} \sim t(n - 1)$$

5. 성별에 따른 평균 임금상승의 차이(독립표본 T검정, Employee data)

집단통계량				
	성별	N	평균	표준편차
임금상승	여자	216	12939.9537	5661.08478
	남자	258	21140.3876	12557.05702

독립표본 검정									
Levene의 등분산 검정					평균의 동일성에 대한 T검정				
		F	유의확률	t	자유도	유의확률 (양측)	평균차이	표준오차 차이	차이의 95% 신뢰구간 하한 상한
임금상승	등분산을 가정함	72.872	.000	-8.872	472	.000	-8200.43389	924.34610	-10016.77646 -6384.09133
	등분산을 가정하지 않음			-9.409	370.806	.000	-8200.43389	871.51097	-9914.15753 -6486.71026

1) 등분산을 가정 시 왜 472일까?

(1) 모분산이 같은 경우($\sigma_1^2 = \sigma_2^2 = \sigma^2$)

유의확률은 다음과 같은 경우에 계산된다.

$$|T| = \frac{|\bar{x} - \bar{y}|}{s \sqrt{\frac{1}{n} + \frac{1}{m}}} > t(n+m-2; \frac{\alpha}{2})$$

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2 + \sum_{j=1}^m (y_j - \bar{y})^2}{(n-1) + (m-1)}$$

2) 등분산을 가정하지 않으면 왜 370.806일까?

$$\frac{\left(\left(\frac{5661.08478^2}{216} \right) + \left(\frac{12557.05702^2}{258} \right) \right)}{\left(\frac{5661.08478^2}{216} \right)^2 / (216-1) + \left(\frac{12557.05702^2}{258} \right)^2 / (258-1)} \doteq 370.806$$

(2) 모분산이 다른 경우($\sigma_1^2 \neq \sigma_2^2$)

유의확률은 다음과 같은 경우에 계산된다.

$$|T| = \frac{|\bar{x} - \bar{y}|}{\sqrt{\frac{s_1^2}{n} + \frac{s_2^2}{m}}} > t(\phi^*; \frac{\alpha}{2})$$

여기서 ϕ^* 는 Satterthwaite의 자유도로 다음과 같이 구한다.

$$\phi^* = \frac{\left(\frac{s_1^2}{n} + \frac{s_2^2}{m} \right)^2}{\left(\frac{s_1^2}{n} \right)^2 / (n-1) + \left(\frac{s_2^2}{m} \right)^2 / (m-1)}$$

6. 자유도가 크면 좋을까?

t 분포


❖ 표준정규분포와 유사한 모양, 단 두꺼운 꼬리부분(fat tail) ① $X \sim N$,

❖ 0을 중심으로 좌우 대칭

② 0모름때 사용.

$$\frac{\bar{X} - \mu}{S/\sqrt{n}}$$

❖ 자유도 (degrees of freedom)는 분포가 퍼져있는 정도를 결정, 자유도가 클수록 가운데로 모이고, 표준정규분포로 수렴



7. 분산분석 가정 3가지(참고. survey.sav 직책 - 전반적만족도)

- 1) 정규성
- 2) 등분산성
- 3) 독립성

8. 회귀분석 시 순서

- 1) 산점도, 상관계수 확인
- 2) 회귀모형 적합
- 3) 모형에 대한 유의성 검정
 - F검정
- 4) 개별 회귀계수에 대한 유의성 검정
 - t검정
- 5) 적합도
 - R^2 , $\hat{\sigma}^2$
- 6) 회귀진단
 - 잔차검정(모형에 대한 가정 확인 -> 모형 오차항의 선형성, 등분산성, 정규성, 독립성)
 - 이상점, 영향점
 - 다중공선성(중회귀모형)
 - 변수선택(중회귀모형)