

보강: 트랜스포머

김광수

2024년 1학기 기계학습 특강
전북대 통계학과

Outline

소개

어텐션

인코더와 디코더(encoder & decoder)

트랜스포머의 주요 성질

비전 트랜스포머(ViT)

소개 I

참고:

https://uvadlc-notebooks.readthedocs.io/en/latest/tutorial_notebooks/tutorial6/Transformers_and_MHAttention.html

- ▶ 어텐션(attention)은 최근 주목받고 있는 신경망의 다층구조 처리 방법들의 일종으로, 노드 간의 영향력을 모형화 함 / 트랜스포머는 seq-to-seq 문제를 푸는 방법론에서 출발하여 다른 여러 문제들도 푸는 알고리즘으로 발전
- ▶ **어텐션:** 중요도를 반영한 seq. 원소들의 가중평균을 이용 (여기에서 중요도는 쿼리와 키의 조합으로 역동적으로 계산됨)

소개 II

- ▶ **트랜스포머(transformer)**는 딥 어텐션 모듈과 위치에 대한 인코딩(encoding)을 핵심요소로 하는 인코더(encoder)와 디코더(decoder)로 구성
- ▶ 모형 측면에서 트랜스포머는 입력이 순차데이터이고 출력이 순차데이터인 곳에서 사용되며, 컴퓨터 비전과 기타 문제로 확장이 가능
- ▶ 마스킹을 이용한 자기지도학습(self-supervised learning)과 관련 있는 방법임

어텐션 I

어텐션의 구성 요소

▶ 아래 네 가지


1. 쿼리(Query): 속성 벡터로 순차데이터에서 어떤 원소가 나머지 원소들에서 어떻게 정보를 가져올 것인가를 나타내는 기본 정보
2. 키(Keys): 이 역시 원소의 속성 벡터로 다른 원소를 설명할 수 있는 정보가 있는지, 중요도가 얼마나 되는지를 나타냄 (참고로 쿼리가 정해지면 이에 따라 키값이 따라오며, 같은 원소라도 쿼리에 따라 키값이 바뀜)

어텐션 II

3. 값(Values): 각 원소들이 내주는 값으로 이를 가중평균을 해서 인코딩을 하게 됨
4. 스코어 함수(Score function): 각 원소들이 내주는 값으로 가중평균을 할 때, 그 값들의 비중은 스코어 함수로 평가됨, 어텐션의 핵심은 스코어 함수에 있으며 쿼리와 키는 이를 위한 도구라고 볼 수 있음

어텐션 III

- 어떤 원소가 주어지면 쿼리와 키 그리고 값을 각각 구성해서 스코어 함수를 계산하고 이로부터 가중 평균을 이용한 인코딩을 하게 되는데, 세 개의 원천이 같으면 이를 self-attention 이라고 함



$$\alpha_i = \frac{\exp(f_{\text{attn}}(\text{key}_i, \text{query}))}{\sum_j \exp(f_{\text{attn}}(\text{key}_j, \text{query}))}$$

어텐션 IV

스케일 내적(Scale Dot Production)

- ▶ 기본 설정

$$Q \in \mathbb{R}^{T \times d_k}, K \in \mathbb{R}^{T \times d_k}, V \in \mathbb{R}^{T \times d_v}$$

- ▶ 여기에서 QK^T 는 원소들 간의 쌍에 대해서 계산된 거리들을 모아 놓은 행렬과 유사한 것으로 T 는 순차데이터의 길이임
- ▶ 어텐션 함수

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) V$$

- ▶ 최종 결과는 길이가 T 인 순차데이터이며 각 원소들은 d_v 의 속성벡터를 가지고 있음: 참고로 모든 순차데이터의 원소는 임베딩된 벡터임

어텐션 V


- ▶ 왜 $\sqrt{d_k}$ 로 나누는가?

$$q_i \sim \mathcal{N}(0, \sigma^2), \quad k_i \sim \mathcal{N}(0, \sigma^2),$$

$$\text{Var} \left(\sum_{i=1}^{d_k} q_i k_i \right) = \sigma^2 d_k,$$

which implies $\text{Var} \left(\sum_{i=1}^{d_k} q_i k_i / \sqrt{d_k} \right) = \sigma^4$.

Scaled Dot-Product Attention




어텐션 VI

- ▶ $X \in \mathbb{R}^{T \times k}$ 에 대한 Self-attention

$$Q = XW^Q, W^Q \in \mathbb{R}^{k \times d_k}$$

$$K = XW^K, W^K \in \mathbb{R}^{k \times d_k}$$

$$V = XW^V, W^K \in \mathbb{R}^{k \times d_v}$$



어텐션 VII

멀티헤드(multi-head) 어텐션

- ▶ 예로 들면 동사를 설명하는데 주어가 중요할 수도 있지만 목적어가 중요할 수도 있는데, 이것이 하나의 어텐션에서 다 모형화되면 좋지만 다중의 어텐션을 이용하는 것이 더 도움이 될 수 있음

어텐션 VIII

- ▶ 여러 개의 어텐션 모듈을 열로 합침

$$\begin{aligned} & \text{Multi-head}(Q, K, V) \\ &= \text{Concat}(\text{head}_1, \dots, \text{head}_h) W^O. \end{aligned}$$


여기에서

$$\text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V),$$


그리고

$$W_i^{Q,K} \in \mathbb{R}^{D \times d_k}, W_i^V \in \mathbb{R}^{D \times d_v},$$

$$W^O \in \mathbb{R}^{d_v h \times d_{out}}.$$



어텐션 IX



Biomedical document triage using a hierarchical attention-based capsule network. September 2020, BMC Bioinformatics 21(Suppl 13):380 DOI:10.1186/s12859-020-03673-5

어텐션 X


위치 인코딩 (Positional Encoding)

- ▶ 현재 사용하고 있는 방법은 순차데이터의 위치가 바뀌어도 같은 결과를 줄 수 있는 permutation-invariant 한 성질을 가지고 있음
- ▶ 순차데이터의 경우 시계열적 구조를 가지고 있거나 언어의 경우도 어순이 중요한 경우가 많으므로 순차 즉 위치 정보를 추가로 임베딩해 줄 필요가 있음
- ▶ 실제 사용되는 위치 정보는 너무 복잡하지 않으면서도 상호 위치 관계를 잘 표현하는 것이 요구되며, 이에 다음 장의 함수 형태가 제안됨

어텐션 XI



$$PE_{pos,i} = \begin{cases} \sin\left(\frac{pos}{10000^{i/d_{model}}}\right) & \text{even} \\ \cos\left(\frac{pos}{10000^{(i-1)/d_{model}}}\right) & \text{odd} \end{cases}$$

- ▶ 여기에서 (pos, i) 는
순차데이터에서의 위치 그리고
숨겨진 차원 (즉, 모형의 모든 층에
연결된 위치 정보를 의미함)



어텐션 XII

▶ 예열방식의 학습율.



인코더와 디코더(encoder & decoder) I

▶ 기본 블록


1. 첫 부분:

$$\text{Layer}(x + \text{Multi-head}(x, x, x))$$

스킵 커넥션(skip connection):
그래디언트 흐름을 원활히 하고 원
자료의 정보를 최대한 유지함

2. 둘째 부분:


$$\begin{aligned}\text{FFN}(x) &= \max(0, xW_1 + b_1)W_2 + b_2 \\ x &= \text{LayerNorm}(x + \text{FFN}(x))\end{aligned}$$



▶ 기본 블록을 N 개를 쌓아감

인코더와 디코더(encoder & decoder) II


▶ 예제 1



인코더와 디코더(encoder & decoder) III

▶ 예제 2

Anomaly examples on CIFAR100




인코더와 디코더(encoder & decoder) IV

디코더

- ▶ 일차 디코더: (다음 출력값 예측을 위한) 출력에 대한 일차 디코더는 인코더와 같은 구조를 통해서 진행
- ▶ 이차 디코더: 쿼리와 키는 입력의 인코더를 값은 출력의 디코더를 이용해서 진행

참고: 예측 방식은 지금까지 예측된 순차값을 가지고 이를 출력으로 받아 다음 출력값을 예측하는 방식임



트랜스포머의 주요 성질 I

- ▶ 계산에 소요되는 시간은 $O(T^2)$ 가 주요 부분이며 여기에서 T 는 순차데이터의 길이임
- ▶ 확장 가능성이 크고 모형의 능력(크기)도 매우 큼
- ▶ 데이터를 추가로 입력할수록 성능 향상이 관측되는 등, 빨리 과적합이 도달하지 않음

비전 트랜스포머(ViT) I

- ▶ 비전 트랜스포머 (2021)
- ▶ 선행연구
 - Cordonnier et al. (2020): 이미지를 2X2 크기의 패치로 쪼개서 순차데이터 구조의 self-attention에 이용, 적은 크기로 인한 한계가 뚜렷
 - image GPT (Chen et al., 2020): 이미지 크기나 색을 줄여서 순차데이터 구조 생성을 연구
- ▶ 기본 동기는 패치로 쪼개서 순차데이터로 이용하는 것임


비전 트랜스포머(ViT) II



- ▶ 패치를 (P, P) 크기로 만들어 총 N 개의 패치를 만듬, 각각의 패치 이미지를 완전화 벡터화해 $N \times P^2C$ 의 행렬을 얻음
- ▶ 여기에서 $D = N \times P^2C$ 로 하고 다음 장의 아키텍처로 네트워크를 구성함

비전 트랜스포머(ViT) III

▶ 아키텍처의 인코더



forward pass - embedding

<https://daebaq27.tistory.com/108>

비전 트랜스포머(ViT) IV

▶ 세부 요소들

1. 위치 임베딩 (여기에서는 학습 가능한 모수를 이용해서 진행): 크기는 $(N + 1) \times D$ 로 여기에 $N \times D$ 의 패치로부터 얻은 행렬속성을 더함

2. 어텐션과 멀티헤드

어텐션:

$$[\mathbf{q}, \mathbf{k}, \mathbf{v}] = \mathbf{z}\mathbf{U}_{sa}, \mathbf{U}_{sa} \in \mathbb{R}^{D \times 3D_h}$$

$$\mathbf{A} = \text{softmax}\left(\frac{\mathbf{q}\mathbf{k}^T}{\sqrt{D_h}}\right)$$

$$\text{SA}(\mathbf{z}) = \mathbf{A}\mathbf{v}$$


멀티헤드:

$$\text{MSA}(\mathbf{z}) = [\text{SA}_1(\mathbf{z}); \text{SA}_2(\mathbf{z}); \dots; \text{SA}_k(\mathbf{z})]\mathbf{U}_{msa}, \mathbf{U}_{msa} \in \mathbb{R}^{D_h k \times D},$$

Here, $D_h = D/k$.

비전 트랜스포머(ViT) V

3. 다층퍼셉트론: 마지막에 두 개의 층으로 구성하되 GELU (Gaussian Error Linear Unit) 함수를 이용.



$$\text{GELU}(x) = x\Phi(x). \text{ } \text{https://hongl.tistory.com/236}$$


비전 트랜스포머(ViT) VI

▶ ViT의 특징

1. CNN에 비해서 조금 더 구조적 제약이 약함 (less inductive bias)
2. 많은 데이터를 집어 넣어도 과적합이 쉽게 안 일어남
3. 실제 학습에 많은 데이터가 필요함
4. 실험에서는 같은 예측오차에 대한 계산량이 ResNet에 비해서 적었음

비전 트랜스포머(ViT) VII

▶ 내재적 결과 분석의 예



멀티헤드의 행동 분석으로 y축이 값이 클수록 더 넓은 범위의 이미지를 축약하고 있다. 의미임, <https://hongl.tistory.com/108>