
주간 회의

Topic : Comparative Analysis of Human and
Multiple LM Responses

Index

1 기초 통계량 분석

2 품사 분석

3 TF-IDF

2 SBERT

데이터 & 방법론

Data : Claude, Deep Seek, Gemini, GPT , Human(Quora)

연구 : 최근 비약적으로 발전하고 있는 거대 언어 모델(LLM)이 생성한 텍스트가 인간이 작성한 텍스트와 얼마나 구분되는지, 더 나아가 서로 다른 LLM 모델들이 생성한 텍스트끼리도 구분이 가능한지를 탐구

LLM system message prompt 종류


1. 중립 & 최소한의 지침
2. 깊이 있는 답변 유도
3. 정보성 강조
4. 경험 공유 강조

기초통계량 분석


Char_count : 단어 수

- GPT가 압도적으로 긴 답변을 생성함
- Claude와 Deepseek의 답변길이는 일관되게 짧음


중립 & 최소한의 지침




깊이 있는 답변 유도



정보성 강조




경험 공유 강조




기초통계량 해석

- Lexical_density(어휘 밀도)에서 Deep Seek와 Claude가 평균 0.74 로 높게 나타남
반면, GPT는 평균 0.63, Human 0.63으로 상대적으로 낮은 어휘 밀도를 보임
- Unique_word_count(고유 어휘 수) – GPT는 답변 길이만큼 평균적으로 가장 많은 어휘를 사용
- GPT는 전반적으로 매우 상세하고 많은 정보를 제공하려함, 때로는 상황(쓸모 없는) 이야기가 많음
- 반면, Deep Seek 나 Claude는 상대적으로 더 간결하면서도 정보 밀도가 높아 보임


중립 & 최소한의 지침




깊이 있는 답변 유도



정보성 강조




경험 공유 강조




기초통계량 해석

- Lexical_density(어휘 밀도)에서 Deep Seek와 Claude가 평균 0.74 로 높게 나타남
반면, GPT는 평균 0.63, Human 0.63으로 상대적으로 낮은 어휘 밀도를 보임
- Unique_word_count(고유 어휘 수) – GPT는 답변 길이만큼 평균적으로 가장 많은 어휘를 사용
- GPT는 전반적으로 매우 상세하고 많은 정보를 제공하려함, 때로는 상황(쓸모 없는) 이야기가 많음
- 반면, Deep Seek 나 Claude는 상대적으로 더 간결하면서도 정보 밀도가 높아 보임


중립 & 최소한의 지침




깊이 있는 답변 유도



정보성 강조




경험 공유 강조




기초통계량 해석 결과

- Human answer은 LLM 보다 평균 단어 길이가 현저히 짧고, 어휘 밀도도 낮은 경향을 보임
- 또한, 상대적으로 평균 문장 길이가 짧음
- 모든 통계량에서 Human answer은 높은 분산을 보임


중립 & 최소한의 지침




깊이 있는 답변 유도



정보성 강조




경험 공유 강조




품사 분석

- 명사, 동사, 형용사, 부사, 인칭 대명사, 전치사 등 품사 사용 빈도 분석
- 계산 : 품사 단어 수 / 전체 단어 수
- Human answer의 명사(NN) 및 동사(VB) 사용 비율이 높음
 - Human이 더 직접적으로 서술하는 경향이 있을 수 있음


중립 & 최소한의 지침




깊이 있는 답변 유도



정보성 강조



경험 공유 강조



품사 분석





- 명사, 동사, 형용사, 부사, 인칭 대명사, 전치사 등 품사 사용 빈도 분석
- 계산 : 품사 단어 수 / 전체 단어 수
- Human answer의 명사(NN) 및 동사(VB) 사용 비율이 높음
 - Human이 더 직접적으로 서술하는 경향이 있을 수 있음

중립 & 최소한의 지침

깊이 있는 답변 유도

정보성 강조


경험 공유 강조




품사 분석

- Human answer이 LLM 보다 인칭 대명사(PRP) 사용 비율이 매우 높음
 - 질문 중 개인적인 의견, 감정 표현 등 주관성을 드러내는 질문이 많음에 따라 높아질 것으로 예상
 - 실제 경험 기반의 답변에서 나오는 자연스러운 경험 표현


중립 & 최소한의 지침




깊이 있는 답변 유도



정보성 강조




경험 공유 강조




품사 분석

- GPT는 다른 LLM들 및 Human에 비해 전치사나 종속접속사(IN)를 많이 사용하여 문장 구조를 더 복잡하게 만듦
- 모든 부분에서 전반적으로 Human answer의 분포의 폭이 넓음
 - 즉, Human answer의 스타일이 LLM 보다 훨씬 다양하고 비정형적임


중립 & 최소한의 지침




깊이 있는 답변 유도



정보성 강조



경험 공유 강조



TF-IDF

4개의 다른 system prompt 에서 얻은 TF-IDF 상위 키워드 및 Human 상위 키워드

Human : people, back, get, know, got, black, one, good, hole, like, day, balck hole, would, dating days, don't

GPT : black (4/4), life (4/4), social (3/4), might (3/4), one (3/4), people (3/4), dating (3/4), also (2/4) often (2/4), sometimes (2/4), others (2/4), someone (2/4), lead (2/4), like (2/4), time (2/4) felt (2/4), made (2/4), im (2/4).

Gemini : im (3/4), life (3/4), would (2/4), black (3/4), like (3/4), feeling (2/4), social (3/4), might (2/4) online (2/4), dating (2/4), even (3/4), someone (3/4), one (3/4), ultimately (2/4), thats (2/4), wasnt (2/4), think (2/4), really (2/4), honestly (2/4), felt (2/4), oh (2/4), id (2/4).

Cluade : people (4/4), social (4/4), someone (4/4), rather (3/4), would (3/4), might (3/4), without (3/4) sometimes (3/4), ive (3/4), dating (3/4), youre (2/4), others (2/4), particularly (2/4) something (3/4) like (2/4), im (2/4), actually (1/4), id (1/4), think (1/4), really (1/4), one (1/4), got (1/4).

Deepseek : like (4/4), youre (3/4), people (3/4), even (3/4), feel (3/4), social (3/4), one (3/4), time (3/4), small (3/4) things (2/4), without (2/4), someone (2/4), dont (2/4), quantum (2/4), honestly (2/4), really (2/4), id (1/4) oh (2/4), man (2/4).

TF-IDF

Human answer vs LLM

- Human answer에서 got, back, day, days 와 같이 구체적인 과거 경험이나 사건을 묘사할 때 자주 사용되는 일상적인 동사나 시간 관련 명사들이 자주 나옴, 일부 LLM에서도 나타나지만 순위가 낮음

Deepseek

- Youre, feel, oh 와 같은 비격식적?이고 대화체적인 표현들이 일관되게 나옴

Claude


- people, social, someone 와 같은 사회적 관계와 관련된 단어 및 rather, without 와 같은 구문적 단어가 일관되게 나옴

GPT


- 스타일 전환 폭이 크지만, black, life 처럼 질문의 핵심 단어가 일관되게 나타남

SBERT


중립 & 최소한의 지침




깊이 있는 답변 유도



정보성 강조




경험 공유 강조




- LLM 모델들은 서로 높은 유사성(0.6 ~ 0.8)을 보임
 - 서로 다른 LLM이라도 동일 질문에 대해 의미적으로 유사한 답변을 생성
- LLM 답변과 Human 답변 간의 평균 유사도는 0.4 ~ 0.5로 일관되게 낮음
 - 내용 혹은 스타일에서 차이가 존재

SBERT


중립 & 최소한의 지침




깊이 있는 답변 유도



정보성 강조



경험 공유 강조



- Human 답변의 내부 일관성은 평균 0.405로 모든 LLM 보다 매우 낮음
 - LLM은 일관된 의미를 반복 생성하는 반면, Human은 동일 질문에도 다양한 의미를 가짐