

CH15. Variable Selection

■ Mean Squared Error (MSE)

$$\text{MSE}(\hat{\theta}) = E[(\hat{\theta} - \theta)^2]$$

- $\hat{\theta}$: the estimator of the parameter θ
- θ : the true parameter value

$$\Rightarrow \text{MSE}(\hat{\theta}) = \text{Var}(\hat{\theta}) + \text{Bias}(\hat{\theta}, \theta)^2$$

■ Mean Squared Error (MSE)

$$\text{MSE}(\hat{\theta}) = E(\hat{\theta} - \theta)(\hat{\theta} - \theta)^{\top}$$

- $\hat{\theta}$: the estimator of the parameter θ
- $\theta = (\theta_1, \dots, \theta_p)$: the true p -dimensional parameter parameter

$$\Rightarrow \text{MSE}(\hat{\theta}) = \text{Var}(\hat{\theta}) + \text{Bias}(\hat{\theta}, \theta)\text{Bias}(\hat{\theta}, \theta)^{\top}$$

■ 완전모형 (Full Model)

$$\mathbf{y} = X_p \boldsymbol{\beta}_p + \boldsymbol{\epsilon}$$

- $X_p = (\mathbf{1}, \mathbf{x}_1, \dots, \mathbf{x}_q, \mathbf{x}_{q+1}, \dots, \mathbf{x}_p) = (X_q, X_r)$
- $\boldsymbol{\beta}_p = \begin{pmatrix} \boldsymbol{\beta}_q \\ \boldsymbol{\beta}_r \end{pmatrix}$, $\boldsymbol{\beta}_p : (p+1) \times 1$, $\boldsymbol{\beta}_q : (q+1) \times 1$, $\boldsymbol{\beta}_r : r \times 1$

$$\Rightarrow \mathbf{y} = X_q \boldsymbol{\beta}_q + X_r \boldsymbol{\beta}_r + \boldsymbol{\epsilon}$$

■ 축소모형 (Reduced Model)

$$\mathbf{y} = X_q \boldsymbol{\beta}_q + \boldsymbol{\epsilon}$$

■ 최소제곱추정량

- Full Model

$$\hat{\beta}_p = \begin{pmatrix} \hat{\beta}_q \\ \hat{\beta}_r \end{pmatrix} = (X_p^\top X_p)^{-1} X_p^\top \mathbf{y}$$

- Reduced Model

$$\tilde{\beta}_q = (X_q^\top X_q)^{-1} X_q^\top \mathbf{y}$$

■ 축소모형에서의 최소제곱추정량

- 편의추정량

$$E(\tilde{\beta}_q) = \beta_q + (X_q^\top X_q)^{-1} X_q^\top X_r \beta_r$$

- 평균제곱오차(MSE)

$$\text{MSE}(\tilde{\beta}_q) = \text{Var}(\tilde{\beta}_q) + \left[E(\tilde{\beta}_q) - \beta_q \right] \left[E(\tilde{\beta}_q) - \beta_q \right]^\top$$

예측

■ 평균반응 예측

- $\mathbf{x}_0 = (1, x_{01}, \dots, x_{0p})^\top = (\mathbf{x}_{0q}^\top, \mathbf{x}_{0r}^\top)^\top$ 가 주어졌을 때 $E(y|\mathbf{x}_0)$ 예측
- 완전모형에서의 예측

$$\hat{y}_{0p} = \mathbf{x}_0^\top \hat{\boldsymbol{\beta}}_p = \mathbf{x}_{0q}^\top \hat{\boldsymbol{\beta}}_q + \mathbf{x}_{0r}^\top \hat{\boldsymbol{\beta}}_r$$

- 축소모형에서의 예측

$$\tilde{y}_{0q} = \mathbf{x}_{0q}^\top \tilde{\boldsymbol{\beta}}_q$$

■ 평균반응 예측의 성질

- $E(\hat{y}_{0p}) = \mathbf{x}_0^\top \boldsymbol{\beta}_p$
- $Var(\hat{y}_{0p}) = \sigma^2 \mathbf{x}_0 (X_p^\top X_p)^{-1} \mathbf{x}_0$
- $E(\tilde{y}_{0q}) = \mathbf{x}_{0q}^\top \boldsymbol{\beta}_p + \mathbf{x}_{0q} (X_q^\top X_q)^{-1} X_q^\top X_r \boldsymbol{\beta}_r$
- $Var(\tilde{y}_{0q}) = \sigma^2 \mathbf{x}_{0q}^\top (X_q^\top X_q)^{-1} \mathbf{x}_{0q}$

정리

〈정리 15.1〉 행렬 $Var(\hat{\beta}_q) - Var(\tilde{\beta}_q)$ 는 양반정치(positive semi-definite)행렬이다.

〈정리 15.2〉 $Var(\hat{y}_{0p}) \geq Var(\tilde{y}_{0q})$

〈정리 15.3〉 만약 $Var(\hat{\beta}_r) - \beta_r \beta_r^\top$ 이 양반정치행렬이면 $Var(\hat{\beta}_q) - MSE(\tilde{\beta}_q)$ 도 양반정치행렬이며, 또한

$$Var(\hat{y}_{0p}) \geq MSE(\tilde{y}_{0q})$$

이 성립한다.

변수 선택

■ 변수 선택 시 고려 사항

- y 에 영향을 미칠 수 있는 모든 설명변수 x 를 사용하여 y 의 값을 예측해야 한다. 그렇지 않으면 $\hat{y}$ 의 편의가 증가할 수 있다.
- 설명변수가 많을수록 데이터를 수집, 분석하고 변수들의 변화를 탐지, 관리하는 데 많은 노력이 요구될 뿐 아니라, $\hat{y}$ 의 분산이 증가할 수 있어 가능한 범위 내에서 적은 수의 설명변수를 포함해야 한다.

Criteria for variable selection

- 잔차평균제곱(residual mean square)

$$MSE_p = \frac{SSE_p}{n - p - 1}$$

- 결정계수(coefficient of determination)

$$R_p^2 = 1 - \frac{SSE_p}{SST}$$

- 수정결정계수(adjusted coefficient of determination)

$$R_{Adj,p}^2 = 1 - \left(\frac{n - 1}{n - p - 1} \right) (1 - R_p^2)$$

- 총제곱오차(total squared error)

$$C_p = \frac{SSE_p}{\hat{\sigma}^2} + 2(p + 1) - n$$

Criteria for variable selection

■ Information Criterion

- Akaike Information Criterion (AIC : 1974)

$$AIC = n \ln \frac{SSE_p}{n} + 2p$$

- Bayesian Information Criterion (BIC : 1978)

$$BIC = n \ln \frac{SSE_p}{n} + p \ln(n)$$

Criteria for variable selection

■ Mallows의 C_p

$$C_p = \frac{SSE_p}{\hat{\sigma}^2} + 2(p + 1) - n$$

- $MSE(\tilde{y}_p) = Var(\tilde{y}_p) + bias(\tilde{y}_p)^2$,

$$\Gamma_p = \frac{1}{\sigma^2} \sum_{j=1}^n MSE(\tilde{y}_{pj}) = \frac{E(SSE_p)}{\sigma^2} + 2(p + 1) - n$$

: standardized total mean squared error

- C_p : Γ_p 의 추정값

Criteria for variable selection

■ Mallows의 C_p

$$C_p = \frac{SSE_p}{\hat{\sigma}^2} + 2(p+1) - n$$

- If $X_p^\top X_r = O_n$ or $\beta_r = \mathbf{0}_r$,

$$\begin{aligned} E(C_p \mid X_p^\top X_r = O_n \text{ 또는 } \beta_r = \mathbf{0}_r) \\ &= \frac{(n-p-1)\sigma^2}{\sigma^2} + 2(p+1) - n \\ &= p+1. \end{aligned}$$

- $C_p \leq p+1$ 이면 좋은 모형

Variable Selection

■ 변수 선택의 방법

- (1) 전역탐색법(Exhaustive search method, All possible regressions)
- (2) 후진제거법(backward elimination method)
- (3) 전진선택법(forward selection method)
- (4) 단계적 선택법(stepwise selection method)

Variable Selection

■ 예제 : Hald 데이터

관측번호	x_1	x_2	x_3	x_4	y
1	7	26	6	60	78.5
2	1	29	15	52	74.3
3	11	56	8	20	104.3
4	11	31	8	47	87.6
5	7	52	6	33	95.9
6	11	55	9	22	109.2
7	3	71	17	6	102.7
8	1	31	22	44	72.5
9	2	54	18	22	93.1
10	21	47	4	26	115.9
11	1	40	23	34	83.8
12	11	66	9	12	113.3
13	10	68	8	12	109.4

전역탐색법

- 모든 가능한 설명변수의 조합에 대한 회귀모형을 적합하여 최적의 모형 선택
- p 개의 설명변수가 있는 경우, 모든 가능한 조합의 경우의 수 :

$$\sum_{k=0}^p \binom{p}{k} = \sum_{k=0}^p \frac{p!}{(p-k)!k!} = 2^p$$

- p 가 증가할 수록 기하급수적으로 증가

전역탐색법

■ 예제

p	회귀모형	R_{ap}^2	R_p^2	MSE_p
0	$\hat{y} = f(1)$	0	0	226.31
1	$\hat{y} = f(x_1)$	0.4915	0.5339	115.06
	$\hat{y} = f(x_2)$	0.6360	0.6663	82.39
	$\hat{y} = f(x_3)$	0.2210	0.2859	176.31
	$\hat{y} = f(x_4)$	0.6449	0.6745	80.35
2	$\hat{y} = f(x_1, x_2)$	0.9744	0.9787	5.79
	$\hat{y} = f(x_1, x_3)$	0.4578	0.5482	122.71
	$\hat{y} = f(x_1, x_4)$	0.9670	0.9725	7.48
	$\hat{y} = f(x_2, x_3)$	0.8164	0.8470	41.54
	$\hat{y} = f(x_2, x_4)$	0.6161	0.6801	86.89
	$\hat{y} = f(x_3, x_4)$	0.9224	0.9353	17.57
3	$\hat{y} = f(x_1, x_2, x_3)$	0.9764	0.9823	5.35
	$\hat{y} = f(x_1, x_2, x_4)$	0.9764	0.9823	5.33
	$\hat{y} = f(x_1, x_3, x_4)$	0.9751	0.9813	5.65
	$\hat{y} = f(x_2, x_3, x_4)$	0.9637	0.9728	8.20
4	$\hat{y} = f(x_1, x_2, x_3, x_4)$	0.9736	0.9824	5.98

■ 예제 : 표본상관계수

	x_1	x_2	x_3	x_4	y
x_1	1	0.2286	-0.8241	-0.2454	0.7307
x_2	0.2286	1	-0.1392	-0.9730	0.8163
x_3	-0.8241	-0.1392	1	0.0295	-0.5347
x_4	-0.2454	-0.9730	0.0295	1	-0.8213
y	0.7307	0.8163	-0.5347	-0.8213	1

후진제거법

■ 변수 선택 절차

- (1) 모든 변수를 포함한 회귀모형을 적합
- (2) 모형에 포함된 모든 변수에 대하여 부분 F -검정(partial F -test) 실시
- (3) 가장 작은 부분 F -검정치를 F_L 이라 놓고,
 - ▶ F_{α_B} : 유의수준 α_B 에서 F -분포의 기각치
 - ▶ 만약 $F_L < F_{\alpha_B}$ 이면, F_L 의 값을 준 설명변수 x_i 를 제거하고, 나머지 변수만을 가지고 회귀모형을 적합 후 (2)번으로
 - ▶ 만약 $F_L \geq F_{\alpha_B}$ 이면, 현재 모형에 있는 변수들을 최종 모형으로 선택

후진제거법

■ 특징

- p 가 클 경우 매우 유용
- 최적모형을 위한 변수들의 조합을 찾지 못할 위험이 존재
- 후진제거법에서 비교할 회귀모형의 최대개수

$$p + (p - 1) + \cdots + 2 + 1 = \frac{p(p + 1)}{2}$$

- 한 번 제거된 변수는 다시 모형이 포함될 수 없음

후진제거법

■ 예제 : Full Model

$$\begin{aligned}\hat{y} &= f(x_1, x_2, x_3, x_4) \\ &= \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \hat{\beta}_3 x_3 + \hat{\beta}_4 x_4 \\ &= 62.4052 + 1.5511x_1 + 0.5102x_2 + 0.1019x_3 - 0.1441x_4\end{aligned}$$

- $R^2 = 0.9824, MSE = 5.98$

$$\widehat{\text{Var}}(\hat{\beta}_1) = 0.5547 \quad \widehat{\text{Var}}(\hat{\beta}_2) = 0.5239$$

$$\widehat{\text{Var}}(\hat{\beta}_3) = 0.5696 \quad \widehat{\text{Var}}(\hat{\beta}_4) = 0.5027$$

후진제거법

■ 예제 : 부분 F -검정치

$$x_1 : F_0 = \frac{\hat{\beta}_1^2}{\widehat{\text{Var}}(\hat{\beta}_1)} = 4.3376, \quad x_2 : F_0 = \frac{\hat{\beta}_2^2}{\widehat{\text{Var}}(\hat{\beta}_2)} = 0.4968$$

$$x_3 : F_0 = \frac{\hat{\beta}_3^2}{\widehat{\text{Var}}(\hat{\beta}_3)} = 0.0182, \quad x_4 : F_0 = \frac{\hat{\beta}_4^2}{\widehat{\text{Var}}(\hat{\beta}_4)} = 0.0413$$

- $F_L = 0.0182, F_{\alpha_B} = F_{0.05}(1, 8) = 5.32$
- $F_L < F_{\alpha_B}$ 이므로 설명변수 x_3 제거

후진제거법

■ 예제 : x_1, x_2, x_4

$$\begin{aligned}\hat{y} &= f(x_1, x_2, x_4) \\ &= \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \hat{\beta}_4 x_4 \\ &= 71.6482 + 1.4519x_1 + 0.4161x_2 - 0.2365x_4\end{aligned}$$

- $MSE = 5.3303$

후진제거법

■ 예제 : 부분 F -검정치

$$x_1 : F_0 = \frac{\hat{\beta}_1^2}{\widehat{\text{Var}}(\hat{\beta}_1)} = 154.0080$$

$$x_2 : F_0 = \frac{\hat{\beta}_2^2}{\widehat{\text{Var}}(\hat{\beta}_2)} = 5.0259$$

$$x_4 : F_0 = \frac{\hat{\beta}_4^2}{\widehat{\text{Var}}(\hat{\beta}_4)} = 1.8633$$

- $F_L = 1.8633$, $F_{\alpha_B} = F_{0.05}(1, 9) = 5.12$
- $F_L < F_{\alpha_B}$ 이므로 설명변수 x_4 제거

후진제거법

■ 예제 : x_1, x_2

$$\hat{y} = f(x_1, x_2)$$

$$= 52.5773 + 1.4683x_1 + 0.6623x_2$$

- $R^2 = 0.9787, MSE = 5.3303$

- 부분 F -검정치

$$x_1 : F_0 = 146.5229, \quad x_2 : F_0 = 208.5823$$

- $F_L = 146.5229 > F_{\alpha_B} = F_{0.05}(1, 10) = 4.96 \Rightarrow \text{중단}$

- 최종모형으로 선택

■ 변수 선택 절차

(0) 절편만 있는 모형에서 시작

(1) 설명변수 중에서 반응변수 y 와 가장 상관관계가 높은 변수(x_p 라고 하자) 선택

- ▶ 회귀모형 $\hat{y} = f(x_p)$ 가 유의한가를 유의수준 α_F 에서 F -검정
- ▶ 설명변수 x_p 가 유의하지 않으면 선택할 변수는 없다고 판정. 유의할 경우 (2)번으로.

■ 변수 선택 절차 (계속)

(2) 나머지 설명변수를 각각 추가하여 회귀모형 적합

- ▶ R^2 을 가장 크게 하는 설명변수 x_i 를 선택(x_q 라고 하자)
- ▶ x_q 에 대하여 유의수준 α_F 에서 부분 F -검정(partial F-test) 실시
- ▶ 유의하면 다음 변수 선택을 위해 (2) 반복
- ▶ 유의하지 않으면, 중단하고 이전단계에서의 모형을 최종모형으로 선택

전진선택법

■ 특징

- p 가 클 경우 매우 유용
- 최적모형을 위한 변수들의 조합을 찾지 못할 위험이 존재
- 전진제거법에서 비교할 회귀모형의 최대개수

$$p + (p - 1) + \cdots + 2 + 1 = \frac{p(p + 1)}{2}$$

- 한 번 포함된 변수는 제거되지 않음

전진선택법

■ 예제 : Starting Model - x_4 선택

요 인	제공합	자유도	평균제공	F_0	$F_{0.05}(1, 11)$
회 귀	1381.8968	1	1831.8698	22.7985	4.84
잔 차	883.8668	11	80.3515		
계	2715.7636	12			

- $\alpha_F = 0.05$ 에서 $\hat{y} = f(x_4)$ 는 유의하므로 x_4 선택

전진선택법

■ 예제 : R^2 비교

$$\hat{y} = f(x_1, x_4) : R^2 = 0.9725, \quad \hat{y} = f(x_2, x_4) : R^2 = 0.6801$$

$$\hat{y} = f(x_3, x_4) : R^2 = 0.9353$$

● x_1 에 대한 부분 F 검정

$$F_0 = \frac{\hat{\beta}_1^2}{\widehat{\text{Var}}(\hat{\beta}_1)} = \frac{1.43996^2}{0.019159} = 108.225$$

- ▶ 기각치 : $F_{\alpha_F} = F_{0.05}(1, 10) = 4.96$
- ▶ $F_0 > F_{\alpha_F}$ 이므로 설명변수 x_1 추가

전진선택법

■ 예제 : R^2 비교

$$\hat{y} = f(x_4, x_1, x_2) : R^2 = 0.9823,$$

$$\hat{y} = f(x_4, x_1, x_3) : R^2 = 0.9813$$

• x_2 에 대한 부분 F 검정

$$F_0 = \frac{\hat{\beta}_2^2}{\widehat{\text{Var}}(\hat{\beta}_2)} = \frac{0.4161^2}{0.03445} = 5.0258$$

▷ 기각치 : $F_{\alpha_F} = F_{0.05}(1, 9) = 5.12$

▷ $F_0 < F_{\alpha_F}$ 이므로 설명변수 x_2 추가 할 수 없음

• 최종모형 : $\hat{y} = 103.09738 + 1.43996x_1 - 0.61395x_4$

단계적 전진선택법

■ 변수 선택 절차

(1) 전진선택법의 [(0)], [(1)]과 동일

(2) 추가 단계

- ▶ R^2 을 가장 크게 하는 설명변수 x_i 를 선택(x_q 라고 하자)
- ▶ x_q 에 대하여 유의수준 α_F 에서 부분 F -검정(partial F-test) 실시
- ▶ 유의하면 (3) 으로
- ▶ 유의하지 않으면, 중단하고 이전단계에서의 모형을 최종모형으로 선택

단계적 전진선택법

■ 변수 선택 절차 (계속)

(3) 제거 단계

- ▶ 모형에 포함된 x_q 를 제외한 나머지 변수에 대해서 유의수준 α_F 에서 부분 F -검정(partial F-test) 실시
- ▶ 유의하지 않은 변수 제거 (2)번으로

단계적 전진선택법

■ 특징

- p 가 클 경우 매우 유용
- 최적모형을 위한 변수들의 조합을 찾지 못할 위험이 존재
- 전진제거법에서 비교할 회귀모형의 최대개수
- 새로 추가되는 변수가 유의한 경우, 이미 포함되어 있던 변수들이 계속 유의한지를 검토

단계적 전진선택법

■ 예제 : (추가단계) R^2 비교

$$\hat{y} = f(x_1, x_4) : R^2 = 0.9725, \quad \hat{y} = f(x_2, x_4) : R^2 = 0.6801$$

$$\hat{y} = f(x_3, x_4) : R^2 = 0.9353$$

● x_1 에 대한 부분 F 검정

$$F_0 = \frac{\hat{\beta}_1^2}{\widehat{\text{Var}}(\hat{\beta}_1)} = \frac{1.43996^2}{0.019159} = 108.225$$

- ▶ 기각치 : $F_{\alpha_F} = F_{0.05}(1, 10) = 4.96$
- ▶ $F_0 > F_{\alpha_F}$ 이므로 설명변수 x_1 추가

단계적 전진선택법

■ 예제 : (제거단계)

- x_4 에 대한 부분 F 검정

$$F_0 = \frac{\hat{\beta}_4^2}{\widehat{\text{Var}}(\hat{\beta}_4)} = \frac{(-0.61395)^2}{0.002366} = 159.31$$

- ▶ 기각치 : $F_{\alpha_B} = F_{0.05}(1, 10) = 4.96$
- ▶ $F_0 > F_{\alpha_B}$ 이므로 설명변수 x_4 는 제거할 수 없음

단계적 전진선택법

- 예제 : (추가단계) R^2 비교

$$\hat{y} = f(x_4, x_1, x_2) : R^2 = 0.9823$$

$$\hat{y} = f(x_4, x_1, x_3) : R^2 = 0.9813$$

- x_2 에 대한 부분 F 검정

$$F_0 = \frac{\hat{\beta}_2^2}{\widehat{\text{Var}}(\hat{\beta}_2)} = \frac{0.4161^2}{0.03445} = 5.0258$$

- ▶ 기각치 : $F_{\alpha_F} = F_{0.05}(1, 9) = 5.12$
- ▶ $F_0 < F_{\alpha_F}$ 이므로 설명변수 x_2 추가 할 수 없음

- 최종모형 : $\hat{y} = 103.09738 + 1.43996x_1 - 0.61395x_4$

단계적 전진선택법

- 예제 : (추가단계 : $\alpha_F = 0.1$) R^2 비교

$$\hat{y} = f(x_4, x_1, x_2) : R^2 = 0.9823,$$

$$\hat{y} = f(x_4, x_1, x_3) : R^2 = 0.9813$$

- x_2 에 대한 부분 F 검정

$$F_0 = \frac{\hat{\beta}_2^2}{\widehat{\text{Var}}(\hat{\beta}_2)} = \frac{0.4161^2}{0.03445} = 5.0258$$

- ▶ 기각치 : $F_{\alpha_F} = F_{0.1}(1, 9) = 3.36$
- ▶ $F_0 > F_{\alpha_F}$ 이므로 설명변수 x_2 추가

단계적 전진선택법

■ 예제 : (제거단계) $F_{\alpha_B} = F_{0.05}(1, 9) = 5.12$

- x_4 에 대한 부분 F 검정

$$F_0 = \frac{\hat{\beta}_4^2}{\widehat{\text{Var}}(\hat{\beta}_4)} = \frac{(-0.2365)^2}{0.03003} = 1.86$$

▷ $F_0 < F_{\alpha_B}$ 이므로 설명변수 x_4 는 제거

- x_1 에 대한 부분 F 검정

$$F_0 = \frac{\hat{\beta}_1^2}{\widehat{\text{Var}}(\hat{\beta}_1)} = \frac{(1.4519)^2}{0.01369} = 153.98$$

▷ $F_0 > F_{\alpha_B}$ 이므로 설명변수 x_1 는 제거할 수 없음

▷ x_1, x_2 를 선택하고 다음 단계로

단계적 전진선택법

■ 예제 : (추가단계 : $\alpha_F = 0.1$) R^2 비교

$$\hat{y} = f(x_4, x_1, x_2) : R^2 = 0.98233, \hat{y} = f(x_3, x_1, x_2) : R^2 = 0.98228$$

- x_4 에 대한 부분 F 검정 : $F_0 = 1.86$
 - ▷ 기각치 : $F_{\alpha_F} = F_{0.1}(1, 9) = 3.36$
 - ▷ $F_0 < F_{\alpha_F}$ 이므로 설명변수 x_4 추가 못함
- 최종모형 : $\hat{y} = f(x_1, x_2)$

$$\hat{y} = 52.5773 + 1.4683x_1 + 0.6623x_2$$