

응용통계학 HW05

1. “dt1.csv” 다음의 데이터는 Helms (1974)에서 수집한 것으로 변수는 다음과 같다.

y = change of rut depth in inches/million wheel passes

x_1 = viscosity of asphalt

x_2 = percentage of asphalt in surface course

x_3 = percentage of asphalt in base course

x_4 = indicator variable to separate two sets of runs

x_5 = percentage of fines in surface course

x_6 = percentage of voids in surface course

네 번째의 가변수는 다음에 실려 있는 31개의 데이터를 얻을 때 처음의 16개와 뒤의 15개가 시간상으로 차이를 두고 얻어졌으므로 이를 구분하기 위하여 나타낸 변수이다. 처음의 16개의 데이터는 $x_4 = -1$ 로 하고 나중 15개는 $x_4 = 1$ 로 하여 주었다. **y 와 x_1 을 로그변환 하여 분석한다.** 다음 물음에 답하여라.

- (1) 중회귀모형을 적합하여라. (주의 : x_4 는 범주형 변수이다.)
- (2) 변수들간의 상관계수를 구하여라.
- (3) 설명변수 6개를 모두 사용한 완전모형(full model)에 대한 분산분석표를 작성하고 $\alpha = 0.05$ 에서 선형회귀모형의 유의성을 검정하시오.
- (4) 상관계수들을 보고 변수를 하나만 선택할 때에는 어떤 변수가 선택될 것인지를 말하시오.
- (5) 상관계수들을 보고 변수를 하나만 제거시키려고 할 때, 어떤 변수가 제거될 것인가를 말할 수 있는가?
- (6) 모든 가능한 회귀모형에 대하여 C_p 값을 구하여라.
- (7) C_p 값이 작을 수록 좋은 모형이라고 할 때, 위의 결과를 보고 $p = 1, 2, 3, 4, 5, 6$ 인 각각의 경우에 대하여 어떤 변수들이 선택되는지 구하시오.
- (8) 위의 C_p 값들로부터 (a)에서 선택된 여섯 가지 경우에 대하여 MSE_p , R_p^2 , R_{ap}^2 을 구하시오.
- (9) 위의 C_p 를 최소로 하는 p 는 무엇인가? MSE_p 를 최소로 하는 p 는?
- (10) 위의 최적 C_p , MSE_p , R_{ap}^2 으로부터 가장 적절한 p 의 값을 최종적으로 선택한 후, 어떤 변수들이 선택되었는지 회귀모형을 쓰시오.
- (11) 후진제거법, 전진선택법 그리고 단계적 전진선택법을 사용하여 MSE_p 를 기준으로 가장 적절한 회귀모형을 구하시오. (참고 : drop1/add1 함수를 이용할 때에 RSS값의 자유도가 모두 동일하기 때문에 MSE_p 를 기준으로 하는 것과 RSS를 기준으로 하는 것은 동일한 결과를 얻을 수 있다.)

(12) (10), (11)의 결과를 비교하여라.

2. “hipcenter.csv” 데이터는 다음의 변수로 이루어져 있다.

- Age : Age in years
- Weight : Weight in lbs
- HtShoes : Height in shoes in cm
- Ht : Height bare foot in cm
- Seated : Seated height in cm
- Arm : lower arm length in cm
- Thigh : Thigh length in cm
- Leg : Lower leg length in cm
- hipcenter : horizontal distance of the midpoint of the hips from a fixed location in the car in mm

“hipcenter”를 예측하기 위한 모형을 적합하려고 한다. 다음 물음에 답하여라.

- (1) 변수들 사이의 산점도행렬을 그리고 설명하여라.
- (2) 변수들 사이의 상관계수를 구하여라. (소수점 둘째자리까지 반올림) 다중공선성이 존재한다고 할 수 있는가?
- (3) 선형회귀모형을 적합하여라. (계수를 추정. 예 : $\hat{y} = 3 + 2x$ 이렇게 적어주기)
- (4) 위의 선형회귀모형에서 개별 회귀계수의 유의성 검정 결과와 (1),(2)번 결과와 연관지어 설명하여라.
- (5) car 패키지의 vif 함수를 이용하여 각 설명변수의 vif값을 구하여라. 다중공선성이 존재한다고 할 수 있는가?
- (6) condition number를 구하여라. 다중공선성이 존재한다고 할 수 있는가?
- (7) glmnet 함수를 이용하여 능형회귀모형을 적합하고자 한다.
 - (a) λ 의 값에 따라 회귀계수가 변하는지 그림으로 보여라. (이 때 $0 < \lambda < 100$ 으로 설정)
 - (b) 교차검증을 수행하였을 때, MSE를 가장 작게 하는 λ 는 무엇인가?
 - (c) 위의 λ 에 대한 능형회귀 추정량은 무엇인가?