

01

소개

주변 환경과 상호작용하면서 배운다는 생각은 아마도 학습의 특성에 대해 생각할 때면 가장 먼저 떠오르는 생각일 것이다. 아기가 놀거나 팔을 휘두르거나 주위를 둘러볼 때, 아기에게 무언가를 가르쳐 주는 사람은 없지만 아기의 감각과 운동은 직접적으로 주변 환경과 연결되어 있다. 이러한 연결을 반복해서 경험하다 보면 인과관계, 행동의 결과, 목적을 이루기 위해 해야 할 것들에 대한 정보가 쌓이게 된다. 살아가는 동안 그러한 상호작용을 통해 자신과 주변의 환경에 대해 배운다는 사실에는 의심의 여지가 없다. 자동차 운전을 배울 때나 다른 사람과 대화를 계속 이어갈 때도 행동의 주체는 주변 환경이 행동에 어떻게 반응하는지를 예민하게 인지하고 있으며, 자신의 행동을 통해 주변에서 일어나는 일에 영향을 미치려고 한다. 상호작용으로부터 배운다는 것은 학습과 지능에 관한 거의 모든 이론의 기저에 깔린 개념이다.

이 책에서는 상호작용으로부터 배우는 과정에서 **컴퓨터를 활용하는**computational 방법을 탐구한다. 현실 세계에서 사람이나 동물이 어떻게 학습하는지 설명하는 이론을 단번에 도출하기보다는 이상적인 학습 환경을 가정하고 그 안에서 다양한 학습 방법이 갖는 효과를 분석한다.¹ 다시 말해, 인공지능 연구자나 엔지니어의 시각에서 문제를 다룬다는 것이다. 과학이나 경제 분야에서 다루어지는 학습의 문제를 효과적으로 해결하는 기계를 어떻게 설계할 것인지에 관해 탐구하고, 그러한 기계의 성능을 수학적 분석과 컴퓨터 실험을 통해 분석한다. 이 책에서 다루게 될

1 심리학 및 신경과학과의 관계는 14장과 15장에 요약되어 있다.

강화학습reinforcement learning이라고 불리는 방법은 기계학습에 속하는 다른 어떤 방법보다 상호작용으로부터 배우는 목표 지향적인 학습에 더욱 초점을 맞춘 방법이다.

1.1 강화학습

강화학습이란, 주어진 상황에서 어떠한 행동을 취할지를 학습하는 것을 의미한다. 이때 그 행동의 결과는 최대한의 보상(또는 이득)을 가져다주어야 하며, 그 보상 함수는 수치적으로 표현될 수 있어야 한다. 학습자agent는 어떤 행동을 취할지에 대한 어떠한 지침도 받지 않고 오로지 시행착오를 통해 최대의 보상을 가져다주는 행동을 찾아내야만 한다. 가장 흥미로우면서도 어려운 상황은 특정 행동이 그 행동에 직접적으로 영향을 받는 보상뿐만이 아니라, 그다음에 이어지는 상황에도 영향을 미침으로써 연속적으로 보상에 영향을 미치는 (지연된 보상) 상황이다. 시행착오와 지연된 보상이라는 특성은 강화학습을 다른 방법과 구분하는 가장 중요한 두 가지 특성이다.

기계학습machine learning이나 등산mountaineering과 같이 그 이름이 '~하기'로 끝나는 많은 주제와 마찬가지로 강화학습reinforcement learning은 하나의 문제이기도 하고, 그 문제를 잘 해결할 수 있는 방법이기도 하며, 그 문제와 해결 방법을 연구하는 분야이기도 하다. 이 세 가지 모두에 대해 하나의 이름을 사용하는 것이 편리한 점도 있지만, 동시에 이들의 개념을 구분할 필요도 있다. 특히, 문제와 그 해결 방법을 구별하는 것은 강화학습에서 매우 중요하다. 이 구분을 제대로 하지 못하면 많은 혼란스러운 상황과 마주치게 된다.

강화학습 문제를 동적 시스템 이론의 개념, 특히 불확실한 마르코프 결정 과정Markov Decision Process, MDP에 대한 최적 제어 이론을 활용하여 체계화했다. 이러한 체계화 과정의 자세한 내용은 3장에서 다룬다. 하지만 기본 아이디어는 목적을 위해 주변 환경과 상호작용하는 학습자가 직면하는 현실적인 문제의 가장 중요한 측면을 포착하는 것이다. 학습자는 주변 환경의 상태를 어느 정도까지는 감지하고 그 상태에 영향을 주는 행동을 취할 수 있어야만 한다. 학습자는 또한 주변 환경의 상태와 관련된 하나 이상의 목표를 가져야만 한다. 가장 간단한 형태의 마르코프 결정 과정은 감지, 행동, 목표라는 세 가지 측면만을 포함한다. 하지만 셋 중 어떤 것도 사소하게 다루지는 않는다. 이러한 문제를 푸는 데 적합한 모든 방법이 바로 강화학습 방법이다.

강화학습은 대부분의 기계학습 분야에서 연구되고 있는 **지도학습**supervised learning과는 다르다. 지도학습은 외부 전문가의 지침이 포함된 훈련 예제로부터 학습하는 것이다. 각각의 훈련 예제에는 어떤 상황과 그 상황에서 학습자가 취해야 할 올바른 행동에 대한 지침label이 포함된다. 이것

은 종종 어떤 상황이 속한 범주를 식별하기 위한 지침이 되기도 한다. 이러한 종류의 학습은 시스템의 행동 방식을 예측하거나 일반화함으로써 훈련 예제에 포함되지 않은 상황에서도 시스템이 올바른 행동을 하도록 하는 것을 목표로 한다. 이것은 중요한 학습 방법이지만 상호작용으로부터 학습하는 것에는 적합하지 않다. 상호작용으로부터 학습하는 문제에서는 경험에 의존하여 바람직한 행동의 예제를 찾는다. 이때 바람직한 행동은 어떤 상황에 대해 적합한 대표성을 갖는 행동이다. 학습자는 미지의 영역에서 자신의 경험으로부터 배울 수 있어야 한다. 그렇게 할 때 학습은 최대의 보상을 가져다준다.

강화학습은 기계학습 연구자들 사이에서 소위 **비지도학습** unsupervised learning이라고 불리는 학습 방법과도 구별된다. 비지도학습에서는 보통 지침이 없는 데이터의 집합 안에서 숨겨진 구조를 찾는다. 지도학습과 비지도학습이라는 용어의 어감 때문에 이 두 학습 방법이 기계학습이라는 분야를 완전히 둘로 나누는 것처럼 보이지만, 실제로는 그렇지 않다. 바람직한 행동에 대한 지침을 필요로 하지 않는다는 특성을 공유한다는 이유로 강화학습을 비지도학습의 한 종류라고 생각하고 싶은 유혹을 느낄 수도 있지만, 강화학습은 보상을 최대로 만들기 위해 노력할 뿐 숨겨진 구조를 찾으려고 하지는 않는다. 학습자의 경험을 통해 숨겨진 구조를 찾는 것은 확실히 강화학습에도 도움이 된다. 하지만 그것만으로는 보상을 최대로 만드는 것을 목표로 하는 강화학습 문제를 풀지 못한다. 그래서 강화학습을 지도학습과 비지도학습에 이은 제3의 또는 그들과는 전혀 다른 기계학습 패러다임이라고 생각한다.

다른 학습에서는 찾아볼 수 없는 강화학습만이 갖는 어려운 점은 탐험과 활용 사이를 절충하는 일이다. 많은 보상을 얻기 위해 강화학습 학습자는 과거에 보상을 획득하는 데 효과적이었던 행동들을 선호해야만 한다. 하지만 바로 그러한 효과적인 행동을 발견하려면 과거에 하지 않았던 행동들을 시도해 봐야 한다. 학습자는 보상을 얻기 위해 이미 경험한 행동들을 **활용** exploitation해야 하지만, 한편으로는 미래에 더 좋은 행동을 선택하기 위한 **탐험** exploration을 해야 한다. 탐험과 활용 둘 중 하나만 추구한다면 목적을 이루지 못한다는 것이 문제다. 학습자는 다양한 행동을 시도하고 그중 최상의 보상을 가져올 만한 행동을 계속해서 선호해야 한다. 확률이 지배하는 문제에서는 어떤 행동이 가져올 보상의 기댓값을 높은 신뢰도로 추정하려면 각각의 행동을 여러 번 시도해야 한다. 탐험과 활용의 딜레마는 수십 년 동안 수학자들의 집중적인 연구 대상이었지만 여전히 미해결의 문제로 남아 있다. 현재로서는 탐험과 활용 사이에 균형을 잡는 문제는 최소한 가장 순수한 형태의 지도학습과 비지도학습에서는 발생하지 않는다고 말할 수 있을 뿐이다.

강화학습의 또 다른 핵심은 불확실한 주변 환경과 상호작용하는 목표 지향적인 학습자에 대한 모든 문제를 분명하게 고려한다는 점이다. 이것은 여러 하위 문제를 커다란 하나의 문제로 병합

하는 방법을 제시하지 않은 채 하위 문제들만을 고려하는 다른 많은 방법과 구별되는 특성이다. 예를 들면, 많은 기계학습 연구가 지도학습의 유용성을 분명하게 밝히지도 않고 지도학습을 다룬다고 말한다. 또 다른 예는, 실시간 의사결정을 위한 계획(planning)의 역할을 고려하지 않거나 계획을 위해 필요한 예측 모델이 어디에서 나오는지에 대한 고민 없이 일반적인 목적을 갖는 계획 이론을 개발하는 경우다. 이러한 방법들이 많은 유용한 결과를 도출했지만, 오직 흩어져 있는 하위 문제들에만 초점을 맞춘 것은 심각한 한계다.

강화학습은 상호작용을 하는 완전하고 목표 지향적인 학습자를 처음부터 고려한 상태로 시작한다는 점에서 정반대의 접근법을 취한다. 모든 강화학습 학습자는 분명한 목표가 있고, 주변 환경의 여러 측면을 감지할 수 있으며, 그 환경에 영향을 주기 위한 행동을 선택할 수 있다. 더욱이, 학습자는 자신이 마주한 환경이 불확실하다 하더라도 학습을 수행해야 한다는 사실을 인지한 상태로 학습을 시작한다. 강화학습에 계획을 활용할 때는 환경에 대한 모델을 도출하고 개선하는 방법을 알아야 할 뿐만 아니라, 계획과 행동이 실시간으로 상호작용하도록 해야 한다. 강화학습에 지도학습을 활용할 때는 지도학습의 특정 능력을 활용해야 할 분명한 이유가 있기 때문에 그렇게 하는 것이다. 학습에 관한 연구가 발전하기 위해서는 중요한 하위 문제들을 구별하며 연구해야 한다. 이때 비록 학습자에 대한 세부 사항들이 완전히 밝혀지지 않았을지라도 하위 문제들은 주변 환경과 상호작용하는 완전한 목표 지향적 학습자 내부에서 분명한 역할을 해야만 한다.

상호작용하는 완전한 목표 지향적 학습자라는 개념이 항상 완전한 유기체나 로봇을 의미하는 것은 아니다. 물론, 완전한 유기체나 로봇은 상호작용하는 완전한 목표 지향적 학습자의 좋은 예가 될 수 있지만, 더 큰 행동 체계를 구성하는 각 부분도 이러한 학습자에 포함된다. 이 경우에 학습자는 시스템의 나머지 부분들과는 직접적으로 상호작용하고 시스템 외부의 환경과는 간접적으로 상호작용한다. 간단한 예를 들어, 로봇 배터리의 충전 수준을 확인하고 로봇 제어 아키텍처에 명령을 보내는 학습자를 생각해 보자. 학습자의 외부 환경은 학습자를 제외한 로봇 내부와 로봇 외부의 환경을 모두 포함한다. 이처럼 강화학습의 기본구조가 갖는 보편성을 이해하기 위해서는 가장 분명하게 존재하는 학습자와 그 주변 환경을 머릿속에 그려 봐야 한다.

강화학습의 가장 흥미로운 현대적 특징 중 하나는 그것이 공학 및 과학 분야와 실질적이고 생산적인 상호작용을 한다는 것이다. 인공지능과 기계학습은 통계학이나 최적화 같은 수학 분야와의 통합을 지향하는 큰 흐름이고, 강화학습은 그 흐름의 일부다. 이러한 흐름은 지난 수십 년 동안 이어져 왔다. 예를 들면, 파라미터를 통해 시스템을 모사할 수 있는 강화학습의 능력은 시스템 운영에 대한 연구 결과와 제어 이론에 내재해 있던 ‘차원의 저주(curse of dimensionality)’ 문제를 해결한다. 좀 더 독특한 점은 강화학습이 심리학 및 신경과학이라는 상이한 분야와 상호작용하



며 큰 영향을 주고받은 것이 두 분야 모두에 도움이 되었다는 사실이다. 기계학습의 모든 형태 중에서 사람이나 동물의 학습과 가장 유사한 것이 강화학습이다. 사실, 강화학습의 많은 핵심 알고리즘은 생태계의 학습 체계에서 영감을 얻어 만들어진 것들이다. 그리고 그러한 강화학습의 연구 결과는 실험 결과와 잘 들어맞는 동물학습의 심리학적 모델이나 뇌의 보상 시스템에 대한 믿을 만한 모델을 제공해 주었고, 반대로 그 모델 덕분에 우리는 생태계의 학습 체계를 더 잘 알게 되었다. 이 책에서는 공학 및 인공지능과 관련된 강화학습의 개념들을 14장과 15장에서 설명하는 신경과학 및 심리학의 내용과 연관 지어 설명할 것이다.

마지막으로, 강화학습은 간단하면서도 일반적인 원리를 탐구하고자 하는 인공지능 연구의 큰 경향성과도 부합한다. 1960년대 후반 이후 많은 인공지능 연구자들은 인공지능에 있어서 일반적인 원리는 발견할 수 없다고 단정 지었다. 지능은 특별한 목적을 달성하기 위한 방법과 경험을 다수 확보함으로써 구현되는 것이라고 생각했던 것이다. 기계에 수백만 또는 수십억 개의 관련 지식을 주입하기만 하면 기계가 지능을 갖게 된다고 말하는 사람도 있었다. 사람들은 탐색이나 학습 같은 일반적인 원리에 기반한 방법을 ‘약한 방법’이라고 인식한 반면, 특정한 지식에 기반한 방법을 ‘강한 방법’이라고 생각했다. 이러한 인식은 오늘날에도 흔하게 찾아볼 수 있는 생각이지만, 지배적인 생각은 아니다. 필자의 입장에서 보자면, 이러한 생각은 간단히 말해서 좀 성급한 생각이었다. 일반적인 원리를 발견하기 위해 충분히 노력해 보기도 전에 일반적인 방법은 존재하지 않을 것이라고 단정 지어 버렸으니 말이다. 현대 인공지능 연구의 상당수는 학습과 탐색, 의사결정의 일반 원리를 찾으려고 노력한다. 이러한 원리를 찾기 위해 얼마나 더 먼 길을 가야 할지는 모르지만, 좀 더 단순하고 포괄적인 일반 원리를 찾기 위한 여정에서 강화학습은 분명 거쳐 가야 할 지점이다.

1.2 예제

강화학습을 이해하는 좋은 방법은 강화학습의 발전 과정에 중요한 역할을 했던 예제와 적용 사례를 생각해 보는 것이다. 예를 들면, 다음과 같다.

- 숙련된 체스 선수가 말을 옮길 때 어느 위치로 말을 옮기는 것이 좋을지는 상대의 대응과 그에 대한 재대응을 예상하는 계획, 그리고 즉각적이고 직관적인 판단을 통해 결정된다.
- 석유 정제공장의 효율적 운영을 위해 적응 제어기^{adaptive controller}를 이용하여 엔지니어가 설정한 초기 파라미터를 조정한다. 이때 한계 비용을 고려하여 산출물/비용/품질 사이의 균형을 최적화한다.

- 새끼 가젤은 태어난 지 몇 분 지나지 않아 어렵게 혼자 힘으로 일어서고, 30분 후에는 시속 30km의 속도로 달릴 수 있다.
- 로봇 청소기는 더 많은 쓰레기를 모으기 위해 새 방을 탐색할지, 아니면 충전 스테이션으로 돌아가야 할지를 결정한다. 이러한 결정은 현재 남아 있는 배터리의 양과 얼마나 쉽고 빠르게 충전 스테이션을 찾을 수 있는지에 대한 과거 경험에 의존한다.
- 필Phil은 아침 식사를 준비한다. 이러한 일상적인 일에도 복잡한 조건부 행동 및 목표와 하위 목표 사이의 서로 맞물려 있는 관계들이 작용한다. 찬장으로 가서 찬장을 열고 시리얼 상자 하나를 고른다. 그런 다음, 상자에 손을 뻗고 손으로 잡은 후에 상자를 꺼낸다. 그릇, 숟가락, 우유 팩을 가져오기 위해서는 또 다른 복잡하고 잘 조절된, 상호작용하는 연속적인 행동이 필요하다. 모든 행동의 단계에는 정보를 얻고 목표물에 손을 뻗고 적합한 운동을 하기 위한 연속적인 눈의 움직임이 포함된다. 어떻게 물건을 옮길지 또는 다른 물건을 가져오기 전에 몇몇 물건을 미리 탁자에 가져다 놓는 것이 좋을지에 대한 판단이 계속해서 빠르게 이루어진다. 각 단계는 숟가락 잡기 또는 냉장고에 넣기처럼 그 자체로 목표인 행동으로 구성되며, 동시에 그러한 행동은 시리얼이 준비되었을 때 먹기 위해서는 숟가락이 있어야 한다는, 그래서 궁극적으로는 영양분을 섭취해야 한다는 또 다른 목표를 이루기 위한 과정이 된다. 부지불식간에 필은 자신의 몸 상태에 대한 정보를 통해 자신에게 영양분이 필요한지, 얼마나 배가 고픈지, 어떤 음식이 좋을지를 결정하고 있다.

이러한 예제들은 매우 기본적인 특징을 공유하기 때문에 쉽게 이해할 수 있다. 모든 예제는 학습자와 그를 둘러싼 주변 환경 사이의 상호작용interaction을 다루고 있다. 주변 환경에는 불확실한 uncertainty 요소들이 있지만, 학습자는 목표goal를 이루기 위한 방법을 모색한다. 학습자는 자신의 행동으로 주변 환경의 미래 모습(예를 들면 체스 말의 다음 위치, 정제 공장의 석유 비축 수준, 로봇 청소기의 다음 위치와 미래의 배터리 충전 양)에 영향을 미치고, 결국 미래에 자신이 취할 수 있는 행동과 기회에 영향을 줄 수 있는 권리를 갖는다. 올바른 선택을 하기 위해서는 행동의 간접적인 영향과 지금의 행동이 일정 시간이 지난 후에 미칠 효과를 고려해야 하고, 이를 위해 예지력이나 계획이 필요할 수도 있다.

하지만 앞선 모든 예제에서 행동의 결과를 완전히 정확히 예측할 수는 없기 때문에 학습자는 주변 환경을 자주 모니터링하고 적절한 대응을 해야 한다. 예를 들면, 필은 시리얼이 담긴 그릇에 우유를 붓는 동안 우유가 넘치지 않도록 주의를 기울여야 한다. 모든 예제에서 학습자는 자신이 직접 관찰한 사실을 통해 현 상황이 목표에 얼마나 가까이 다가가 있는지를 판단할 수 있다. 그 때문에 각 예제의 학습자는 자신의 목표를 분명하게 인식할 수 있다. 체스 선수는 자신이 이기

고 있는지 지고 있는지를 알고 있으며, 정제 공장의 제어 시스템은 얼마나 많은 석유가 만들어지고 있는지를 알고 있고, 새끼 가젤은 언제 자신이 넘어질지를 알고 있고, 로봇 청소기는 언제 배터리가 바닥날지 알고 있고, 필은 자신이 아침 식사를 즐기고 있는 것인지 그렇지 않은지를 알고 있다.

이 모든 예제에서 학습자는 자신의 경험을 활용하여 시간이 지남에 따라 행동의 능력을 키우게 된다. 체스 선수는 자신이 선택한 말의 위치가 얼마나 적절한지를 판단하는 데 사용하는 직관력을 키워 더 좋은 위치를 선택하게 되고, 새끼 가젤은 더 효율적으로 달릴 수 있는 방법을 터득하게 되며, 필은 더 쉽고 간편하게 아침 식사를 준비하는 방법을 배우게 된다. 이전의 경험을 활용하거나 또는 설계나 진화를 통해 주입된 지식을 활용하여 학습자가 어떤 일을 시작하려 할 때, 그 지식은 무엇이 유용하고 배우기 쉬운 것인가를 결정하는 데 영향을 미친다. 하지만 학습자가 하려는 일의 분명한 특성을 이용하여 학습자가 행동을 조정하려고 할 때 주변 환경과의 상호작용 과정은 필수적이다.

1.3 강화학습의 구성 요소

학습자와 주변 환경을 제외하고도 강화학습에는 네 가지 주요한 구성 요소가 있다. 바로 **정책** policy, **보상 신호** reward signal, **가치 함수** value function, 그리고 (필수 항목은 아니지만) 주변 환경에 대한 **모델** model이다.

정책은 특정 시점에 학습자가 취하는 행동을 정의한다. 간단히 말해서, 정책이란 학습자가 인지한 주변 환경의 상태에 대해 학습자가 취해야 할 행동을 알려준다. 그것은 심리학에서 말하는 자극-반응의 규칙이나 그와 관련된 것들과 대응된다. 어떤 경우에 정책은 간단한 함수나 열람표 look up table일 수도 있고, 더욱 복잡한 경우에는 탐색 과정에 필요한 방대한 양의 계산을 포함할 수도 있다. 정책 그 자체만으로도 행동을 결정할 수 있다는 점에서 정책은 강화학습 학습자에게 있어 핵심이 되는 부분이다. 일반적으로, 정책은 확률론적으로 행동을 선택할 수도 있다. 이 경우, 정책은 각 행동에 선택될 확률을 부여하고 그 확률에 따라 행동을 선택한다.

보상 신호는 강화학습이 성취해야 할 목표를 정의한다. 매 시간마다 주변 환경은 강화학습을 이용하는 학습자에게 **보상** reward이라고 불리는 하나의 숫자(보상 신호)를 전달한다. 학습자의 유일한 목표는 장기간에 걸쳐 학습자가 획득하게 되는 보상의 총합을 최대로 만드는 것이다. 따라서 학습자는 보상 신호의 크기로부터 자신의 행동이 좋은 것인지 나쁜 것인지를 판단할 수 있

다. 생태계에서는 보상이라는 것이 기쁨이나 고통의 경험과 연결되어 있다고 생각할 수 있다. 보상은 학습자가 직면한 문제를 정의하는 즉각적인 신호다. 보상 신호는 정책을 바꾸는 주된 원인이 된다. 만약 정책이 선택한 행동이 적은 보상을 가져온다면 다음에 유사한 상황이 되었을 때는 다른 선택을 하도록 정책이 바뀔 수 있다. 일반적으로, 보상 신호는 환경의 상태와 취해진 행동에 대해 확률적으로 그 값이 결정되는 확률론적(stochastic) 함수가 될 수도 있다.

보상 신호가 무엇이 좋은 것인가를 즉각적으로 알려주는 반면, 가치 함수는 장기적인 관점에서 무엇이 좋은 것인가를 알려준다. 간단히 말해, 특정 상태의 가치(value)는 그 상태의 시작점에서부터 일정 시간 동안 학습자가 기대할 수 있는 보상의 총량이다. 보상이 어떤 순간에 주변 환경의 상태에 내재된 고유의 장점을 나타낸다면, 가치는 특정 시점 이후의 상태와 그 상태에 포함된 장점을 고려하여 장기적 관점(long-term)으로 평가한 상태의 장점이라고 할 수 있다. 예를 들어, 어떤 상태의 매 순간의 보상은 적지만 큰 보상을 갖는 상태들이 정기적으로 뒤따라온다면 그 상태는 여전히 높은 가치를 갖게 된다. 그 반대의 경우도 마찬가지다. 인간에 빗대어 표현하자면, 큰 보상은 기쁨과 같은 것이고 적은 보상은 고통과 같은 것이다. 반면, 가치란 주변 환경이 특정 상태에 놓여 있는 것이 우리를 얼마나 기쁘게 또는 기분 나쁘게 하는가를 좀 더 정확하면서도 장기적인 관점에서 판단한 지표다.

어떤 면에서 보상은 주된 것이고, 가치는 보상에 대한 예측이므로 부수적이다. 보상 없이는 가치가 있을 수 없고, 가치를 평가하는 것도 오로지 더 많은 보상을 얻기 위해서다. 그런데도 어떤 결정을 내리고 그 결정을 평가할 때 가장 많이 고려하는 것은 가치다. 행동의 선택은 가치에 대한 판단을 기준으로 이루어진다. 보상이 최대인 행동보다는 가치가 최대인 행동을 선택해야 한다. 이렇게 해야 장기적으로 최대한 많은 보상을 얻을 수 있기 때문이다. 하지만 불행하게도 보상이 얼마인지를 결정하는 것보다 가치의 크기를 결정하는 것이 훨씬 더 어렵다. 보상은 주변 환경으로부터 기본적으로 주어지지만, 가치는 학습자의 전 생애주기 동안 학습자가 관찰하는 것들로부터 반복적으로 추정되어야만 한다. 사실, 이 책이 다루는 거의 모든 강화학습 알고리즘에서 가장 중요한 것은 효과적으로 가치를 추정하는 방법이다. 가치 추정이 강화학습에서 핵심적 역할을 한다는 사실은 지난 60년 동안 강화학습에 대해 알게 된 것 중 가장 중요한 것이 틀림없다.

강화학습의 구성 요소 중 네 번째이자 마지막은 환경 모델이다. 환경 모델은 환경의 변화를 모사(mimic)한다. 좀 더 일반적으로는 환경이 어떻게 변화해 갈지를 추정할 수 있게 해 준다. 예를 들면, 환경 모델은 현재 상태와 그에 따라 취해지는 행동으로부터 다음 상태와 보상을 예측한다. 모델은 계획(planning)을 위해 사용되는데, 여기서 계획이란 미래의 상황을 실제로 경험하기 전에 가능

성만을 고려하여 일련의 행동을 결정하는 방법을 의미한다. 모델과 계획을 사용하여 강화학습의 문제를 해결하는 방법을 **모델 기반**(model-based) 방법이라고 한다. 이에 반대되는 개념으로 **모델 없는**(model-free) 방법이 있는데, 이것은 전적으로 시행착오 학습자가 취하는 방법으로 계획과는 거의 정반대의 방법으로 인식된다. 시행착오로부터 환경 모델을 학습하고 동시에 그 모델을 사용하여 계획하는 과정을 수행하는 강화학습 시스템을 8장에서 설명할 것이다. 현대의 강화학습은 시행착오로부터 학습하는 낮은 수준에서부터 심도 깊은 계획을 하는 높은 수준까지의 모든 것을 아우른다.

1.4 한계와 범위

강화학습은 상태(state)라는 개념에 크게 의존하는데, 상태라는 것은 정책과 가치 함수의 입력이 되기도 하고 모델의 입력과 출력이 되기도 한다. 공식적인 정의는 아니지만, 상태란 특정 시각에 환경이 어떤 모습을 하고 있는지에 대한 정보를 학습자에게 전달하는 신호라고 정의할 수 있다. 이 책에서는 마르코프 결정 과정이라는 틀 안에서 상태에 대한 공식적인 정의가 내려지는데, 이에 대해서는 3장에서 설명한다. 하지만 일반적으로 통용되는 비공식적 의미로, 학습자가 사용할 수 있는 환경에 대한 모든 정보를 상태로 생각하는 것이 좋다. 사실, 환경의 기본적 구성 요소인 전처리(preprocessing) 시스템이 상태를 제공한다고 생각할 수 있다. 이 책에서는 상태를 구성하고 변화시키는 것, 또는 상태를 학습하는 것을 (17.3절에서 간략히 다루는 것을 제외하면) 다루지 않는다. 상태의 표현이 중요하지 않다고 생각해서가 아니라, 이렇게 하는 것이 의사결정 문제에 완전히 초점을 맞추는 데 도움이 되기 때문이다. 다시 말해 이 책의 관심사는 상태를 설계하는 것이 아니라, 어떠한 상태가 주어지든 상관없이 그 상태 정보로부터 학습자가 취해야 할 행동을 결정하는 것이다.

이 책에서 다루는 대부분의 강화학습 방법은 가치 함수를 추정하기 위한 것이다. 하지만 강화학습 문제를 풀기 위해 반드시 가치 함수를 추정해야 하는 것은 아니다. 예를 들면 유전자 알고리즘(genetic algorithm), 유전자 프로그래밍(genetic programming), 모의 담금질(simulated annealing) 같은 최적화 방법은 결코 가치 함수를 추정하지 않는다. 이러한 방법은 환경과 오랜 시간 동안 불연속적 시간 간격으로 상호작용하는 다수의 정적 정책(static policy)을 적용한다. 가장 큰 보상을 얻는 정책과 그것의 무작위 변형이 다음 세대의 정책으로 전달되는 일련의 과정을 반복한다. 이 방법의 동작 방식이 생물학적 진화와 비슷하기 때문에 이러한 방법을 **진화적**(evolutionary) 방법이라고 부르는데, 생물학적 진화를 통해 생산된 유기체는 생애주기 동안 학습한 적이 없음에도 노련한 행동을 할

수 있다. 정책의 개수가 충분히 적거나, 또는 좋은 정책을 쉽게 찾을 수 있도록 구조화되어 있는 상황이거나, 그것도 아니면 좋은 정책을 탐색할 시간이 충분한 경우에는 진화적 방법이 효과적이다. 더욱이, 학습자가 환경의 완전한 상태를 감지할 수 없다는 문제를 해결하는 데 진화적 방법이 도움이 된다.

이 책은 환경과 상호작용하며 학습하는 강화학습 방법에 초점을 두고 있다. 이러한 학습은 진화적 방법으로는 해낼 수 없다. 개별 행동의 상호작용이 갖는 세부 사항을 잘 활용할 수 있는 방법들은 많은 경우에 진화적 방법보다 훨씬 더 효율적이다. 진화적 방법은 강화학습 문제의 많은 유용한 구조를 사용하지 않는다. 진화적 방법은 그것이 찾는 정책이 상태에서부터 행동을 도출하는 함수라는 사실을 활용하지 않는다. 진화적 방법은 개별 학습자가 생애주기 동안 어떠한 상태를 통과하는지, 또는 어떠한 행동을 취해야 하는지를 알려주지 않는다. 물론, 어떤 경우에는 이러한 정보를 알려주는 것이 잘못된 행동을 야기할 수도 있지만(❌ 상태를 잘못 판단했을 때), 대부분의 경우에 이러한 정보는 효율적인 탐색을 가능하게 한다. 진화와 학습은 많은 특징을 공유하고 있으며, 따라서 서로 자연스럽게 협력할 수 있다. 하지만 필자는 진화적 방법이 그 자체로는 강화학습 문제와 특별히 잘 어울린다고 보지 않기 때문에 이 책에서는 진화적 방법을 다루지 않는다.

1.5 확장된 예제: 틱택토

강화학습의 일반적인 개념을 설명하고 다른 접근법과의 차이를 드러내기 위해 예제 하나를 좀 더 자세히 들여다보자.

아이들이 하는 익숙한 게임 틱택토tic-tac-toe를 생각해 보자. 세 개의 행과 세 개의 열로 이루어진 격자판을 가지고 두 명이 번갈아 가며 게임을 한다. 한 사람은 X를 표시하고 다른 사람은 O를 표시하여 한 사람이 가로, 세로, 대각선 중 하나의 방향으로 연달아 세 개의 동일한 표시를 하여 이길 때까지 게임을 진행한다. 오른쪽 그림에서는 X를 표시한 사람이 이겼다. 만약

X	O	O
O	X	X
		X

어느 누구도 연달아 세 개를 표시하지 못한 채로 칸이 다 채워졌다면 무승부가 된다. 이 게임에 숙달된 사람이라면 무조건 이기도록 게임을 할 수 있기 때문에, 여기서는 간혹 잘못된 선택을 하여 상대방이 이길 수 있게 해 주는 덜 숙달된 사람과 게임을 하고 있다고 가정해 보자. 사실은 무승부나 지는 것이나 똑같이 안 좋은 결과라고 잠깐 동안만 가정해 보자. 어떻게 하면 상대방의 잘못된 선택을 찾아내고 승리할 확률을 최대로 하는 법을 배우는 학습자를 만들 수 있을까?

이 문제는 간단하지만, 전통적인 방법으로는 만족스러울 정도로 쉽게 풀리지는 않는다. 예를 들어, 게임 이론의 전통적인 '미니맥스(minimax)' 방법은 상대방이 특정한 방법으로 게임을 한다는 가정을 하기 때문에 올바른 해결책이 아니다. 예를 들어, 미니맥스 방법으로 게임을 하는 사람은 비록 상대방의 잘못된 선택 덕분에 특정 상태에 도달하여 그 이후에는 항상 이기는 것이 보장될지라도 결코 절대 질 수 없는 상태에는 도달하지 못한다. 동적 프로그래밍(dynamic programming) 같은 순차적 결정 문제에 대한 전통적 최적화 방법은 어떤 상대방과 게임을 하더라도 최적의 해결책을 계산할 수는 있지만, 이때 상대방에 대한 완벽한 정보가 필요하다. 예를 들면, 상대방이 게임 판의 상황에 따라 특정 선택을 할 확률이 필요하다. 대부분의 실제적인 문제와 마찬가지로 이 예제 문제에서도 상대방에 대한 사전 정보가 제공되지 않는다고 가정하자. 하지만 이러한 경우에도 상대방과 게임을 많이 해 봄으로써 상대방에 대한 사전 정보를 경험으로 추론할 수 있다. 이 문제에 적용할 수 있는 그나마 최선의 방법은 먼저 상대방의 행동에 대한 모델을 어느 정도 자신감을 얻을 때까지 학습하고, 이 근사적 모델과 동적 프로그래밍을 적용하여 최적의 해결책을 계산하는 것이다. 결국, 이것은 이 책에서 다룰 강화학습의 몇몇 방법과 크게 다르지 않다.

이 문제에 진화적 방법을 적용한다면 게임 참여자는 가능한 정책들을 직접 탐색하여 상대방을 이길 확률이 가장 높은 것을 찾으려고 할 것이다. 여기서 정책이란, 게임 참여자에게 게임의 모든 상황, 즉 게임 판 위의 모든 X와 O의 조합에서 어떠한 선택을 해야 할지 알려주는 규칙이다. 모든 정책마다 그 정책이 승리로 귀결될 확률은 상대방과 몇 차례 게임을 함으로써 얻을 수 있다. 이러한 확률 계산을 통해 다음번에는 어떤 정책을 선택해야 할지 알 수 있다. 전형적인 진화적 방법은 정책들이 펼쳐진 언덕을 오르며 연속적으로 정책을 평가하고 더 향상된(이길 확률이 더 높은 **올긴이**) 정책을 찾아간다. 또는 어쩌면 유전자 기반 알고리즘을 사용하여 정책을 평가함으로써 좋은 정책들의 집합을 유지할 수도 있다. 문자 그대로 수백 가지의 최적화 방법을 적용해 볼 수 있다.

이제 가치 함수를 사용하여 어떻게 틱택토 문제에 접근하는지를 말하겠다. 먼저, 게임에서 나타날 수 있는 모든 상태에 숫자 하나씩을 부여하여 숫자 표를 만든다. 각 숫자는 해당 상태에서 게임 참여자가 승리할 확률에 대한 가장 최신의 추정값이다. 이 추정값을 상태의 **가치**(value)로 생각하면 이제 전체 표는 학습된 가치 함수가 된다. 상태 A로부터 승리할 확률이 상태 B로부터 승리할 확률보다 크면, 상태 A가 상태 B보다 높은 가치를 갖는다. 또는 더 낮다고 평가받는다. X를 표시하는 게임 참여자라면 세 개의 X가 연달아 있을 때는 이미 승리한 것이므로 게임 참여자의 승리 확률은 1이다. 마찬가지로, 세 개의 O가 연달아 있거나 이미 게임 판이 모두 채워졌다면 이

상태로부터 승리할 수는 없기 때문에 승리 확률은 0이 된다. 모든 상태의 초기 가치는 0.5로 설정한다. 즉, 승리 확률을 50%로 설정한다.

이제 상대방과 여러 번 게임을 진행한다. X를 표시할 위치를 선택하기 위해 게임 참여자는 (게임 판의 모든 빈칸에 대해) 자신의 선택이 불러올 상태를 면밀히 따져보고 현재 숫자 표의 가치를 확인한다. 게임을 하는 대부분의 시간 동안 게임 참여자는 가치, 즉 승리 확률 추정값을 최대화하는 상태로 가기 위해 X를 표시할 위치를 탐욕적으로 선택한다. 하지만 간혹 X를 표시할 위치를 무작위로 선택하기도 한다. 무작위 선택을 하지 않았다면 경험하지 못했을 상태를 경험하게 해 준다는 의미에서 이러한 선택을 탐험적(exploratory) 선택이라고 한다. 게임을 하는 동안 선택했거나 선택을 고려해 본 위치의 연속적인 고리를 그림 1.1의 다이어그램에서 확인할 수 있다.




그림 1.1 틱택토 선택의 연결 고리. 검은 실선은 게임 도중에 취해진 이동을 나타낸다. 점선은 강화학습을 이용하는 게임 참여자가 고려했지만 선택하지 않은 이동을 나타낸다. 게임 참여자의 두 번째 이동에서, e^* 로 이동하는 것이 더 높은 순위임에도 불구하고 e 로 이동했다는 점에서 이 이동은 탐험적 이동이다. 탐험적 이동은 어떤 학습도 유발하지 않지만, 그 밖의 이동은 붉은 화살표가 나타내는 것처럼 가치를 갱신하며 학습을 유발한다. 본문에 설명한 것처럼 가치 추정값이 나중 노드로부터 붉은 화살표를 따라 이전 노드로 올라간다.

게임을 하는 동안 게임 참여자는 자신이 처한 상태의 가치를 변화시킨다. 게임 참여자는 그 가치가 승리 확률에 대한 좀 더 정확한 추정이 되도록 노력한다. 이를 위해 그림 1.1의 화살표가 나타내듯이 각각의 탐욕스러운 선택 이후 결정될 상태의 가치를 선택 이전의 상태에 보강(backup)한다. 더 정확하게 말하면, 이전 상태의 현재 가치가 나중 상태의 가치에 가까워지도록 갱신된

다. 이것은 이전 상태의 가치를 나중 상태의 가치와 가까워지는 방향으로 일정 부분 변경함으로써 가능하다. 탐욕스러운 선택 이전의 상태를 S_t 라 하고 선택 이후의 상태를 S_{t+1} 이라고 하면, $V(S_t)$ 로 표현되는 S_t 추정값의 갱신은 다음과 같이 나타낼 수 있다.

$$V(S_t) \leftarrow V(S_t) + \alpha [V(S_{t+1}) - V(S_t)]$$

여기서 α 는 시간 간격 파라미터(step-size parameter)라고 불리는 작은 양의 값으로서, 학습의 속도에 영향을 준다. 이 갱신 규칙은 시간차 학습(temporal-difference learning) 방법의 일종이다. 갱신 과정의 변화량이 두 연속적인 시각의 추정값 차이 $V(S_{t+1}) - V(S_t)$ 에 기반하여 계산되기 때문에 시간차 학습으로 불린다.

위에 설명한 방법은 이 문제에 꽤 적합하다. 예를 들어, 시간 간격 파라미터가 시간이 지남에 따라 적절히 줄어든다는 것은 이 방법을 통해 숫자 표의 확률값이 각각의 상태에서부터 승리할 확률의 참값으로 수렴한다는 것을 의미한다. 이러한 해석에는 게임 참여자가 최적의 선택을 한다는 가정이 필요하며, 게임의 상대방은 누가 되든 상관없다. 더욱이, 이러한 상황에서 취해지는 (탐욕적 이동을 제외한) 이동은 (불완전한) 특정 상대방에 대한 최적화된 이동이다. 다른 말로 하면, 이 방법은 특정 상대방과 게임을 하는 최적의 정책으로 수렴한다. 시간 간격 파라미터가 시간이 지나도 0으로 수렴하지 않을 수도 있는데, 그렇다 하더라도 그것은 게임을 수행하는 방법을 느리게 변화시키는 상대방에 대해 게임 참여자가 게임을 잘 수행하고 있음을 의미한다.

이 예제는 진화적 방법과 가치 함수를 학습하는 방법 사이의 차이점을 설명해 준다. 정책을 평가하기 위해 진화적 방법은 정책을 고정한 채로 상대방과 많은 게임을 시도하거나 상대방의 모델을 이용하여 많은 게임을 시뮬레이션해 본다. 승리의 빈도수는 그 정책으로 승리할 확률에 대한 편차 없는(unbiased) 추정값을 의미하며, 다음 정책 선택의 지침이 된다. 하지만 모든 정책의 수정은 많은 게임을 수행한 후에야 이루어지고 오로지 게임의 최종 결과만을 사용하게 된다. 즉, 게임 도중에 무슨 일이 일어나는지는 무시된다. 예를 들어, 게임 참여자가 승리하면 어떤 특정 움직임이 승리에 중요한 기여를 했는지는 상관없이 게임 참여자가 게임 도중 취했던 모든 행동이 신뢰를 받는다. 심지어 발생하지 않았던 움직임에도 신뢰를 부여하게 된다. 반면, 가치 함수를 이용하는 방법은 개별적인 상태들을 평가하는 것을 허용한다. 결국 진화적 방법이나 가치 함수 방법이나 모두 정책을 탐색하지만, 가치 함수를 학습하면 게임 도중에 발생한 정보를 활용할 수 있다는 이점이 있다.

이 간단한 예제는 강화학습 방법의 몇 가지 핵심 특성을 설명한다. 첫째, 강화학습은 주변 환경과 상호작용하며 학습하는 것을 강조한다. 이 예제의 경우에 주변 환경은 게임 상대방이다.

둘째, 강화학습에는 확실한 목표가 있고, 올바른 행동을 위해 학습자가 선택한 행동의 지연된 효과를 고려하는 계획 또는 예지가 필요하다. 예를 들어, 간단한 강화학습을 이용하는 게임 참여자는 근시안적인 상대방에 대해 여러 경로의 합정을 설정하는 것을 학습한다. 상대방에 대한 모델이나 미래 상태 및 행동과의 가능한 연결 고리에 대한 분명한 탐색 없이도 계획과 예지의 효과를 낼 수 있다는 것은 강화학습의 놀라운 특징이다.

이 예제가 강화학습의 핵심적인 특징을 설명하고는 있지만, 예제가 너무 간단해서 강화학습이 좀 더 복잡한 문제에 적용될 때는 많은 한계를 드러낼 것 같은 인상을 주는데, 실제로 강화학습이 갖는 한계는 그보다 적다. 틱택토 게임은 두 사람이 하는 게임이지만, 강화학습은 외부로부터의 작용이 없는 경우, 즉 ‘자연을 상대로 한 게임’의 경우에도 적용할 수 있다. 또한, 틱택토 게임과 같이 학습자의 행동이 여러 개의 에피소드로 분리되어 있고 마지막 에피소드에서만 보상이 주어지는 문제에만 강화학습을 적용할 수 있는 것은 아니다. 강화학습은 행동이 무한히 계속되고 다양한 크기의 보상이 언제든지 주어지는 경우에도 적용할 수 있다. 강화학습은 또한 틱택토 게임처럼 이산적인discrete 시간 간격으로 분해되지 않는 문제에도 적용할 수 있다. 이론이 더 복잡해서 지금 소개하는 단계에서는 생략했지만, 강화학습의 일반적인 원리는 연속적인 시간에 기반을 둔 문제에도 적용할 수 있다.

틱택토 게임에서 상태의 집합은 유한하고 그 크기가 비교적 작지만, 강화학습은 상태들의 집합이 매우 큰, 심지어 무한한 경우에도 적용될 수 있다. 예를 들어, 게리 테사우로(Gerry Tesauro, 1992, 1995)는 위에 설명한 알고리즘을 인공 신경망과 결합하여 대략 10^{20} 개의 상태를 갖는 백게임을 학습하게 했다. 이 경우에는 상태가 너무 많아서 그중 작은 일부분만을 경험할 수 있다. 테사우로의 프로그램은 이전의 어떤 프로그램보다 게임을 훨씬 더 잘하도록 학습했고, 결국에는 인간 세계 챔피언보다 더 잘했다(16.1절 참고). 인공 신경망 덕분에 프로그램은 자신의 경험을 일반화하는 능력을 갖추게 되었고, 그 결과 새로운 상태를 접했을 때 프로그램은 이전에 경험했던 유사한 상태로부터 저장한 정보를 기반으로 인공 신경망을 통해 행동을 결정했다. 이처럼 거대한 상태 집합을 갖는 문제를 강화학습 시스템이 어떻게 해결하는지는 강화학습 시스템이 과거의 경험을 얼마나 적절히 일반화하는지와 밀접한 관련이 있다. 강화학습을 사용하는 지도학습에서 가장 필요한 것이 바로 이러한 역할이다. 인공 신경망과 심층학습(9.7절)이 이러한 역할에 있어서 유일하거나 가장 좋은 방법은 아니다.

틱택토 예제에서 게임의 규칙 이외의 사전 정보 없이 학습이 시작되지만, 강화학습이 지능과 학습에 대해 아무 생각이 없는 것은 결코 아니다. 반대로, 효율적인 학습을 위해 필수적일 수 있는 다양한 방법을 통해 사전 정보는 강화학습에 녹아들 수 있다(예 9.5절, 17.4절, 13.1절 참고). 틱택토

예제에서는 상태의 실제 값을 알 수 있었지만, 상태의 일부 정보가 감추어져 있거나 서로 다른 상태가 같은 상태인 것처럼 보이는 경우에 대해서도 강화학습을 적용할 수 있다.

마지막으로, 틱택토 게임 참여자는 앞을 내다보고 자신의 선택에 따른 상태의 결과를 알 수 있었다. 이렇게 하려면 실제로 취하지 않을 선택에 대해 환경이 어떻게 변할지를 예측할 수 있게 해 주는 게임의 모델이 있어야 한다. 많은 문제들이 이와 같은 모델을 갖고 있지만, 어떤 문제에는 행동의 결과를 짧은 기간 동안 예측하는 모델도 결여되어 있다. 강화학습에는 예측 모델이 필요 없기 때문에 어떠한 문제에도 강화학습을 적용할 수 있다. 모델이 주어진다면 강화학습은 그 모델을 쉽게 사용할 수 있고, 모델이 없더라도 모델을 학습할 수 있다(8장 참고).

반면에 어떠한 종류의 모델도 사용하지 않는 강화학습 방법이 있다. 모델 없는(model-free) 시스템은 심지어 하나의 행동이 환경을 어떻게 변화시킬지를 생각할 능력도 없다. 이러한 점에서 틱택토 게임 참여자는 상대방에 대한 어떠한 종류의 모델도 갖고 있지 않다. 모델이 도움이 되려면 충분히 정확한 모델이어야 하기 때문에, 충분히 정확한 환경 모델을 만드는 어려움이 문제 해결의 걸림돌이 되는 상황에서는 복잡한 방법보다는 모델 없는 방법이 더 도움이 될 수 있다. 모델 없는 방법은 또한 모델 기반 방법을 구성하는 중요한 요소이기도 하다. 이 책에서는 모델 없는 방법에 대해 여러 장에 걸쳐 설명한 이후에 그것이 더 복잡한 모델 기반 방법을 구성하는 데 어떻게 사용되는지 논의할 것이다.

강화학습은 한 시스템의 높은 수준과 낮은 수준 모두에서 사용될 수 있다. 틱택토 게임 참여자는 게임의 기본적인 움직임을 학습했다. 하지만 정교한 문제 해결 방법을 활용하여 행동을 결정하는 경우도 있는데, 이러한 높은 수준에서도 강화학습은 아무런 문제 없이 적용될 수 있다. 계층적 학습 시스템에서 강화학습은 여러 수준에서 동시에 적용될 수 있다.

연습 1.1 자가 게임 무작위의 상대방과 게임을 하는 대신 위에 설명한 강화학습 알고리즘이 양쪽 모두를 학습하며 혼자서 게임을 한다고 가정해 보자. 이 경우에 어떤 일이 벌어질 것 같은가? 강화학습이 이동을 선택하기 위해 서로 다른 정책을 학습할까? □

연습 1.2 대칭성 틱택토 게임의 많은 위치는 서로 달라 보이지만 대칭성 때문에 실제로는 같다. 이러한 성질로부터 도움을 얻기 위해 위에 설명한 학습 과정을 어떻게 수정해야 할까? 이러한 수정이 어떠한 방식으로 학습 과정을 개선할까? 그럼, 이제 다시 생각해 보자. 상대방은 대칭성의 도움을 받지 않는다고 가정해 보자. 이 경우에 우리는 도움을 받을까? 대칭적으로 동일한 위치는 반드시 같은 가치를 갖는다는 것이 사실일까? □

연습 1.3 탐욕적 게임 강화학습으로 무장한 게임 참여자가 탐욕적이어서 항상 자신이 가장 좋다고 생각하는 위치로 움직인다고 가정해 보자. 그는 탐욕적이지 않은 게임 참여자보다 더 잘하도록 학습할까, 아니면 더 못하도록 학습할까? 어떤 문제가 발생할까? □

연습 1.4 탐험으로부터의 학습 탐험적 이동을 포함하여 모든 이동이 끝난 후에 학습에 의한 갱신이 이루어진다고 가정해 보자. 시간 간격 파라미터가 시간에 따라 적절히 감소하면(그렇다고 탐험의 경향이 줄어드는 것은 아니다) 상태의 가치는 서로 다른 확률 세트로 수렴할 것이다. 탐험적 이동을 할 경우와 하지 않을 경우에 계산되는 두 가지 확률 세트는 (개념적으로) 무엇인가? 계속해서 탐험적 이동을 한다고 가정하면 어떤 확률 세트가 학습하기 더 좋을까? 어떤 확률 세트가 더 많은 승리를 가져올까? □

연습 1.5 그 밖의 개선점 강화학습을 사용하는 게임 참여자를 향상시킬 다른 방법이 있을까? 제시된 틱택토 문제를 더 잘 푸는 방법이 있을까? □

1.6 요약

강화학습은 목표 지향적인 학습과 결정을 이해하고 자동화하기 위한 계산적 접근법이다. 예제에 의한 지도^{supervision}나 환경에 대한 완벽한 모델을 필요로 하지 않고, 환경과 직접 상호작용하며 학습하는 것을 강조한다는 점에서 강화학습은 다른 계산적 접근법과 구별된다. 필자의 견해로는, 장기적인 목표를 달성하기 위해 환경과 상호작용하며 학습하는 과정에서 발생하는 계산적 이슈를 진지하게 고민하는 최초의 분야가 강화학습이다.

상태, 행동, 보상의 측면에서 학습자와 환경 사이의 상호작용을 정의하기 위해, 강화학습은 마르코프 결정 과정의 형식적 틀을 사용한다. 이 틀의 목적은 인공지능 문제의 본질적인 특징을 표현하는 간단한 방법을 제공하는 것이다. 이러한 특징에는 원인과 결과의 느낌, 불확실성과 비결정주의의 느낌, 분명한 목적의 존재와 같은 것들이 있다.

가치와 가치 함수의 개념은 이 책에서 다루는 대부분의 강화학습 방법의 핵심이다. 이 책은 정책의 공간에서 효율적인 탐색이 이루어지기 위해서는 가치 함수가 중요하다는 입장을 견지한다. 진화적 방법은 가치 함수를 사용하지 않고 전체 정책을 평가함으로써 정책을 직접적으로 탐색한다. 가치 함수를 사용한다는 점에서 강화학습 방법은 진화적 방법과 구별된다.

1.7 강화학습의 초기 역사

강화학습의 초기 역사에는 두 가지 주요한 갈래가 있다. 이 두 갈래는 모두 오래되고 풍부한 역사를 갖고 있으며, 현대 강화학습에서 합쳐지기 전까지는 각자 독립적으로 발전했다. 한 갈래는 동물 심리학에서 유래되었으며, 시행착오 학습에 관한 것이다. 이 갈래는 인공지능의 가장 초기 연구에 만연한 흐름으로, 1980년대 초 강화학습의 부흥을 이끌었다. 두 번째 갈래는 가치 함수와 동적 프로그래밍을 이용하는 최적 제어의 문제와 그 해결책에 관한 것이다. 대개 이 갈래는 학습을 포함하지 않는다. 두 갈래는 대체로 독립적이지만, 보다 덜 분명한 세 번째 갈래에서는 이 두 갈래가 서로 연관된다. 세 번째 갈래는 바로 이 장의 틱택토 예제에서 사용했던 시간차 방법에 관한 것이다. 1980년대 후반에 세 갈래가 모두 모여 이 책에서 설명하는 현대 강화학습 분야를 만들어 냈다.

시행착오 학습에 초점을 두는 갈래는 우리에게 가장 익숙하고 역사적으로 얘기할 내용도 가장 많다. 하지만 그 얘기를 하기 전에 최적 제어에 관한 갈래를 간략히 살펴보자.

‘최적 제어’라는 용어는 어떤 동역학 시스템의 시간에 따른 결과를 측정하고 그 측정값을 최대 또는 최소화하는 제어기를 설계하는 문제를 설명하기 위해 1950년대 후반에 등장했다. 이 문제에 대한 접근 방법의 하나는 1950년대 중반에 리처드 벨만(Richard Bellman)을 비롯한 학자들에 의해 개발되었는데, 그들은 해밀턴(Hamilton)과 자코비(Jacobi)의 19세기 초 이론을 확장하는 방법을 사용했다. 지금은 벨만 방정식으로 알려진 함수 방정식을 정의하기 위해 이 방법은 동역학 시스템의 상태와 가치 함수, 즉 ‘최적 이득 함수(optimal return function)’를 사용한다. 이 함수 방정식을 풀어서 최적 제어 문제를 해결하는 방법들은 동적 프로그래밍(벨만, 1957a)이라고 알려지게 되었다. 벨만(1957b)은 또한 마르코프 결정 과정(MDP)이라고 알려진 최적 제어 문제를 이산 확률론적(discrete stochastic)으로 다룬 새로운 시각도 제시했다. 로널드 하워드(Ronald Howard, 1960)는 MDP에 대한 정책 반복(policy iteration) 방법을 고안했다. 이 모든 것들은 현대 강화학습의 이론과 알고리즘을 구성하는 필수 요소다.

동적 프로그래밍은 일반적인 확률론적 최적 제어 문제를 푸는 데 있어서 실현 가능한 유일한 방법으로 알려져 있다. 이 방법은 벨만이 ‘차원의 저주(curse of dimensionality)’라고 지칭한 문제, 즉 상태 변수의 개수에 따라 기하급수적으로 계산량이 증가하는 문제가 있긴 하지만, 여전히 다른 어떤 일반적인 방법보다 훨씬 효율적이고 폭넓게 적용할 수 있는 방법이다. 동적 프로그래밍은 1950년대 후반부터 광범위하게 개발되었고, 부분적으로 관측 가능한 MDP(1991, 로베조이(Lovejoy)의 연구), 많은 응용 사례들(1985, 1988, 1993, 화이트(White)의 연구), 근사적 방법(1996, 러스트(Rust)의 연구),